



PROPOSAL

OPTIMASI GERAKAN ROBOT SEPAK BOLA MENGUNAKAN *KALMAN FILTER* PADA DETEKSI OBJEK BERBASIS YOLO

Oleh:

Fikri Rivandi
2207112583

**PROGRAM STUDI TEKNIK INFORMATIKA S1
JURUSAN TEKNIK ELEKTRO
FAKULTAS TEKNIK
UNIVERSITAS RIAU
2025**

DAFTAR ISI

DAFTAR ISI.....	ii
DAFTAR GAMBAR.....	iv
DAFTAR TABEL	v
BAB I PENDAHULUAN.....	1
1.1. Latar Belakang	1
1.2. Rumusan Masalah	5
1.3. Tujuan Penelitian	5
1.4. Batasan Masalah.....	6
1.5. Manfaat Penelitian	6
1.6. Sistematika Penulisan	7
BAB II LANDASAN TEORI	8
2.1. Penelitian Terdahulu	8
2.2. Kompetisi Robot Sepak Bola Beroda Indonesia.....	23
2.3. Robot Sepak Bola Beroda	24
2.4. <i>Convolutional Neural Network</i> (CNN)	25
2.5. Algoritma YOLOv8 (<i>You Only Look Once version 8</i>)	26
2.6. <i>Robot Operating System</i> (ROS)	27
2.7. OpenCV v3.4 (<i>Open Source Computer Vision version 3.4</i>)	29
2.8. NumPy v2.3 (<i>Numerical Python version 2.3</i>).....	30
2.9. <i>Root Mean Square Error</i> (RMSE)	31
2.10. <i>Kalman Filter</i>	32
BAB III METODOLOGI PENELITIAN	37
3.1. Metode Penelitian.....	37

3.2.	Kerangka Pikiran.....	37
3.3.	Studi Literatur	38
3.3.1.	Algoritma Deteksi Objek	38
3.3.2.	Algoritma Prediksi dan Pelacakan	39
3.3.3.	Sistem Robotika dan Kontrol Gerak	39
3.4.	Identifikasi Masalah	39
3.4.1.	Ketidakstabilan Data Deteksi Akibat Keterbatasan Komputasi (<i>Frame Rate Issue</i>).....	39
3.4.2.	Kerentanan Terhadap <i>Occlusion</i> dan <i>False Negative Detection</i> ...	39
3.4.3.	Kebutuhan untuk Prediksi Posisi Gerak Dinamis	40
3.5.	Persiapan Data dan Konfigurasi Model Deteksi	40
3.6.	Implementasi Sistem Deteksi dan Pelacakan	41
3.7.	Desain dan Implementasi Kontrol Gerak Robot Berbasis Visi.....	43
3.8.	Pengujian dan Evaluasi Kinerja	45
3.8.1.	Skenario Pengujian.....	45
3.8.2.	Metrik Evaluasi Kinerja	46
DAFTAR PUSTAKA		48

DAFTAR GAMBAR

Gambar 2.1 Robot Sepak Bola Beroda	24
Gambar 2.2 Arsitektur CNN	26
Gambar 2.3 Ilustrasi Algoritma YOLO	27
Gambar 2.4 ROS (<i>Robot Operating System</i>)	28
Gambar 2.5 Kegunaan OpenCV	29
Gambar 2.6 Logo NumPy	30
Gambar 3.1 Kerangka Pikiran Penelitian.....	38
Gambar 3.2 Strategi Implementasi Sistem Deteksi Dan Pelacakan.....	43

DAFTAR TABEL

Tabel 2.1 Penelitian Terdahulu	16
--------------------------------------	----

BAB I

PENDAHULUAN

1.1. Latar Belakang

Perkembangan teknologi di era modern telah memberikan dampak signifikan pada berbagai aspek kehidupan manusia. Salah satu bidang yang mengalami kemajuan pesat adalah teknologi *Artificial Intelligence* (AI) dan *machine learning* (ML) (Widodo et al., 2024). Teknologi ini memungkinkan sistem komputer tidak hanya melakukan perhitungan, tetapi juga belajar dari data, mengenali pola, serta mengambil keputusan secara mandiri (Wijaya & Yuniarto, 2024). Salah satu cabang dari AI yang banyak dimanfaatkan adalah *computer vision*. *Computer vision* merupakan cabang dari kecerdasan buatan yang berfokus pada kemampuan komputer dan sistem untuk mengekstraksi informasi bermakna dari citra digital, video, maupun data visual lainnya. Informasi yang diperoleh kemudian dapat digunakan untuk mengambil keputusan, memberikan rekomendasi, atau menjalankan suatu tindakan tertentu (Baskoro et al., 2022).

Robotika merupakan bidang interdisipliner yang berfokus pada kajian mengenai robot, di mana ilmu pengetahuan, teknologi, dan rekayasa saling berhubungan. Hasil akhirnya berupa mesin yang dapat menirukan perilaku manusia atau menjalankan instruksi tertentu melalui pemrograman (Hendrik & Awal, 2023). Robot konvensional umumnya didesain untuk beroperasi pada lingkungan yang terstruktur dan terbatas dengan algoritma tugas yang telah diprogram secara statis. Akan tetapi, kenyataannya lingkungan kerja sering bersifat dinamis dan tidak terduga, sehingga dibutuhkan sistem yang lebih adaptif dan fleksibel. Pada titik inilah kecerdasan buatan memiliki peran penting. Dengan memanfaatkan teknologi seperti *machine learning*, *computer vision*, dan kecerdasan buatan lainnya, robot modern mampu mengenali objek, memahami kondisi lingkungan, mengambil keputusan, serta belajar dari pengalaman secara mandiri (Ritonga & Hasibuan, 2025). Salah satu implementasi nyata robotika yang mendapat perhatian khusus adalah robot sepak bola, khususnya dalam Kontes Robot Sepak Bola Indonesia (KRSBI) Beroda.

Universitas Riau (UNRI) memiliki klub robotika bernama *Engineering Robotic Club* (ERC) yang berfokus pada pengembangan robot KRSBI Beroda. Pada tahun 2021 dan 2022, tim ERC UNRI berhasil mencapai tingkat nasional, yang menjadi pencapaian signifikan dalam sejarah keikutsertaannya di KRSBI Beroda. Sejak berpartisipasi pertama kali pada tahun 2019, ERC UNRI telah mengalami berbagai perkembangan signifikan, baik dalam aspek perangkat keras maupun perangkat lunak. Namun, perubahan regulasi sejak tahun 2023 membuat tim harus melakukan penyesuaian ulang agar robot tetap kompetitif dan relevan.

Dalam pertandingan KRSBI Beroda, kemampuan deteksi bola dan gawang menjadi faktor yang sangat krusial. Awalnya, metode deteksi objek berbasis HSV (*Hue, Saturation, Value*) digunakan karena ringan dan dapat berjalan *real-time*. Citra dengan format HSV dimanfaatkan dalam penerapan algoritma *image thresholding* guna mendeteksi warna objek. Selanjutnya, hasil dari proses *thresholding* tersebut digunakan dalam algoritma *Convex Hull*, di mana apabila bola berhasil terdeteksi, maka sistem akan menghitung ukuran objek, menentukan titik pusatnya, serta memperoleh koordinat posisi objek (x, y) relatif terhadap posisi robot saat ini. Kelemahan metode HSV adalah ketergantungannya pada kondisi pencahayaan, sehingga akurasi deteksi menjadi tidak stabil dalam situasi lapangan yang dinamis (Nanda et al., 2023).

Seiring perkembangan teknologi *computer vision*, metode *deep learning* seperti YOLO (*You Only Look Once*) akhirnya digunakan untuk meningkatkan akurasi deteksi objek pada robot KRSBI Beroda milik ERC UNRI. YOLO bekerja dengan membagi citra ke dalam *grid* dan memprediksi *bounding box* serta kelas objek secara langsung dalam satu tahap komputasi, sehingga mampu memberikan deteksi *real-time* dengan akurasi yang tinggi (F. B. Saputra et al., 2023). Secara konsep, metode ini sangat ideal untuk kebutuhan robot sepak bola beroda, yang menuntut respon cepat terhadap pergerakan bola di lapangan.

Namun dalam implementasi YOLO pada robot KRSBI Beroda, masalah pertama yang didapat adalah kendala signifikan terkait keterbatasan sumber daya perangkat keras. Sistem robot saat ini menggunakan laptop ASUS K401U sebagai unit pemrosesan utama, yang hanya memiliki spesifikasi standar seperti prosesor

Intel Core i5 generasi lama, RAM terbatas, serta dukungan GPU yang masih di bawah spesifikasi minimum untuk menjalankan YOLO. Spesifikasi tersebut tidak sebanding dengan kebutuhan komputasi YOLO (misalnya YOLOv8), yang umumnya memerlukan kemampuan paralel tinggi, memori besar, serta akselerasi GPU agar dapat melakukan inferensi secara stabil di *frame rate* tinggi. Akibatnya, proses deteksi sering mengalami penurunan performa, seperti *lag* dan ketidakstabilan *frame rate*, sehingga informasi posisi bola diterima oleh robot dengan jeda waktu. Keterlambatan ini berdampak langsung terhadap kualitas pergerakan robot. Robot dapat terlambat merespons perubahan posisi bola, bergerak tidak stabil, atau bahkan salah memperkirakan arah gerak bola. Dengan kata lain, meskipun YOLO memiliki akurasi tinggi, keterbatasan perangkat keras pada robot KRSBI Beroda menyebabkan efisiensinya menurun dan menjadi salah satu sumber utama masalah dalam sistem navigasi berbasis visi.

Penelitian sebelumnya membuktikan bahwa metode YOLO adalah salah satu cara efektif dalam *object detection*, tapi tidak cukup efisien untuk sumber daya perangkat keras yang digunakan, karena membutuhkan kapasitas komputasi yang mumpuni (Miharja et al., 2025). Pada penelitian lainnya juga menyebutkan bahwa menggunakan perangkat *Single Board Computer* berkinerja tinggi, seperti NVIDIA Jetson Series, juga perlu dipertimbangkan untuk meningkatkan kecepatan deteksi (FPS) guna mencapai performa *real-time* yang lebih optimal (Firdaus & Lelono, 2025).

Selain itu, pada proses deteksi objek juga sering terjadi permasalahan seperti *occlusion* (oklusi) dan *false negative detection* yang merupakan masalah kedua bagi penelitian ini. Fenomena oklusi, di mana sebagian objek tertutup oleh penghalang tertentu, merupakan masalah fundamental dalam deteksi objek. Oklusi merupakan penyebab utama yang meningkatkan *false-negative detection rate*, yang pada dapat menurunkan kinerja deteksi secara keseluruhan. Objek yang teroklusi ini dikategorikan sebagai *hard-positive examples* yang sulit dideteksi oleh model. Oleh karena itu, oklusi dan *false-negative* adalah hal yang harus diperhatikan untuk mencapai optimalitas dalam penggunaan *object detection* (Ryu & Chung, 2021).

Untuk menjawab tantangan tersebut, penelitian ini mengusulkan penggunaan *Kalman Filter* pada hasil deteksi bola berbasis YOLO. *Kalman Filter* merupakan salah satu algoritma estimasi yang banyak digunakan dalam sistem dinamis karena mampu memprediksi keadaan berikutnya dari suatu objek berdasarkan data pengamatan sebelumnya. Metode *Kalman Filter* menggunakan informasi dari objek yang terdeteksi di suatu *frame* dan status objek dari *frame* sebelumnya untuk mendapatkan status yang baru dari objek tersebut (C. Saputra, 2023).

Pada konteks robot sepak bola, *Kalman Filter* sangat relevan untuk digunakan karena bola sering mengalami perubahan posisi secara cepat, mendadak, dan terkadang tidak terduga. YOLO sebagai detektor objek hanya memberikan posisi bola pada setiap *frame*, tanpa mempertimbangkan dinamika gerakan dari bola tersebut. Akibatnya, jika bola bergerak terlalu cepat atau terjadi keterlambatan proses inferensi, robot bisa kehilangan akurasi dalam mengejar bola. Dengan *Kalman Filter*, sistem tidak hanya bergantung pada deteksi saat ini, tetapi juga dapat memprediksi posisi bola pada *frame* berikutnya, sehingga pergerakan robot menjadi lebih stabil, responsif, dan efisien.

Selain itu, *Kalman Filter* memiliki keunggulan dari sisi efisiensi komputasi. Dibandingkan dengan metode prediksi berbasis *deep learning* yang umumnya membutuhkan sumber daya tinggi, *Kalman Filter* relatif ringan dan dapat diimplementasikan pada perangkat dengan keterbatasan komputasi seperti robot KRSBI Beroda. Penelitian sebelumnya yang dilakukan oleh Yuztiawan & Utaminingrum (2017) juga memperkuat hal ini, di mana integrasi model YOLOv8N dengan *Kalman Filter* pada kondisi lingkungan dengan banyak objek mampu meningkatkan akurasi dan stabilitas deteksi serta pelacakan hingga 91,66%. Bahkan, penggunaan *Kalman Filter* terbukti meningkatkan kinerja pelacakan sebesar 25% dibandingkan hanya menggunakan YOLOv8N saja. Menariknya, penambahan algoritma tersebut hanya memberikan tambahan waktu komputasi rata-rata sekitar 0,0076 detik per *frame* (sekitar 7,92%), sehingga sistem tetap mampu bekerja secara *real-time*. Dengan demikian, *Kalman Filter* tidak hanya meningkatkan akurasi pelacakan, tetapi juga tetap mempertahankan efisiensi

komputasi yang sangat penting bagi robot kompetitif dengan keterbatasan perangkat keras.

Berdasarkan permasalahan yang telah diuraikan, peneliti tertarik untuk meneliti dengan judul “Optimasi Gerakan Robot Sepak Bola Menggunakan *Kalman Filter* Pada Deteksi Bola Berbasis YOLO”. Penelitian ini bertujuan untuk mengembangkan dan mengimplementasikan sistem deteksi serta pelacakan bola pada robot KRSBI Beroda dengan memanfaatkan kamera *omnidirectional* dan pendekatan *deep learning* berbasis CNN. Deteksi objek akan dilakukan menggunakan algoritma YOLO, sementara prediksi pergerakan bola diperkuat dengan penerapan *Kalman Filter* untuk mengatasi keterbatasan deteksi berbasis *frame* tunggal. Dengan kombinasi ini, robot diharapkan tidak hanya mampu mengenali bola dan gawang secara akurat, tetapi juga dapat melakukan respon gerakan yang lebih mulus, stabil, dan efisien meskipun bola bergerak cepat atau kondisi lapangan penuh gangguan visual.

1.2. Rumusan Masalah

Berdasarkan latar belakang yang telah diuraikan, maka permasalahan dalam penelitian ini dapat dirumuskan ke dalam beberapa pertanyaan sebagai berikut:

1. Bagaimana meningkatkan kestabilan deteksi bola pada robot KRSBI Beroda ketika algoritma YOLO mengalami keterbatasan performa akibat rendahnya kapasitas perangkat keras (laptop ASUS K401U) sehingga menghasilkan *frame rate* yang tidak stabil dan keterlambatan informasi posisi bola?
2. Bagaimana mengurangi dampak *occlusion* dan *false-negative detection* yang sering terjadi pada proses deteksi bola berbasis YOLO, sehingga robot tetap mampu mengetahui dan memprediksi posisi bola secara konsisten pada kondisi lapangan yang dinamis?

1.3. Tujuan Penelitian

Berdasarkan rumusan masalah yang telah dikemukakan, maka tujuan dari penelitian ini adalah sebagai berikut:

1. Mengembangkan sistem deteksi dan pelacakan bola yang lebih stabil dan responsif pada robot KRSBI Beroda dengan mengoptimalkan proses deteksi YOLO menggunakan algoritma *Kalman Filter* untuk mengatasi keterbatasan perangkat keras.
2. Meningkatkan kontinuitas pelacakan bola dengan memanfaatkan kemampuan prediksi *Kalman Filter* untuk mengurangi pengaruh *occlusion* dan *false-negative detection*, sehingga robot dapat bergerak lebih efisien, tepat sasaran, dan adaptif terhadap dinamika permainan.

1.4. Batasan Masalah

Adapun batasan masalah dari penelitian ini adalah sebagai berikut:

1. Penelitian ini hanya membahas deteksi dan pelacakan bola menggunakan kamera *omnidirectional* pada robot KRSBI Beroda.
2. Algoritma deteksi objek yang digunakan adalah YOLO yang sudah ada, tanpa melakukan pengembangan arsitektur baru.
3. Prediksi posisi bola dilakukan dengan menggunakan *Kalman Filter*, tanpa membandingkannya dengan algoritma prediksi lain.
4. Fokus penelitian adalah pada optimasi gerakan robot terhadap bola, tidak mencakup aspek strategi tim, komunikasi antar robot, atau kontrol *hardware* secara mendetail.

1.5. Manfaat Penelitian

Berikut adalah manfaat dilakukannya penelitian ini bagi beberapa pihak:

1. Peneliti akan memperoleh pengalaman berharga dalam mengimplementasikan algoritma YOLO yang dipadukan dengan *Kalman Filter* pada sistem robotika, khususnya dalam konteks deteksi dan prediksi objek bergerak.
2. Penelitian ini dapat membantu meningkatkan performa robot dalam pertandingan melalui sistem deteksi bola yang lebih akurat dan gerakan robot yang lebih stabil serta efisien.

1.6. Sistematika Penulisan

Untuk mempermudah dalam memahami lebih jelas tentang penulisan penelitian ini, maka penelitian ini ditulis dalam beberapa bab yang masing-masing berkaitan satu sama lainnya, dengan sistematika penulisan sebagai berikut:

BAB I PENDAHULUAN

Bagian ini berisi tentang deskripsi umum dari penelitian yang akan dilakukan meliputi Latar Belakang, Perumusan Masalah, Tujuan Penelitian, Batasan Masalah, Manfaat Penelitian dan Sistematika Penulisan.

BAB II LANDASAN TEORI

Bagian ini membahas penelitian terdahulu, teori-teori dan pendapat para ahli yang berhubungan dengan penelitian yang dilakukan.

BAB III METODOLOGI PENELITIAN

Bagian ini berisi tentang alat dan bahan penelitian yang dilakukan, metode dan alur penelitian, metode pengembangan sistem cerdas, metode pengumpulan data, teknik mengolah data, dan teknik menguji hasil olahan data.

BAB IV HASIL DAN PEMBAHASAN

Bab ini menjelaskan tentang hasil perancangan dan analisa yang telah dilakukan sesuai dengan metodologi penelitian, sekaligus mengevaluasi hasil pengujian terhadap parameter-parameter uji yang telah ditetapkan.

BAB V KESIMPULAN DAN SARAN

Bab ini menjelaskan tentang simpulan hasil penelitian yang diperoleh sesuai dengan tujuan penelitian serta memuat saran mengenai masalah dan kemungkinan pemecahannya untuk penelitian selanjutnya.

DAFTAR PUSTAKA

LAMPIRAN

BAB II

LANDASAN TEORI

2.1. Penelitian Terdahulu

Penelitian mengenai sistem deteksi objek, khususnya dalam penggunaan model *Convolutional Neural Network* (CNN) seperti *You Only Look Once* (YOLO), telah banyak dilakukan sebelumnya. Penelitian-penelitian tersebut memberikan kontribusi penting dalam pengembangan metode deteksi objek maupun optimasi model menggunakan algoritma bantuan seperti estimator. Dengan meninjau penelitian terdahulu, penulis memperoleh wawasan terkait kelemahan metode sebelumnya, potensi pengembangan, serta peluang penerapan algoritma terbaru yang lebih efektif.

Pertama, penelitian yang berjudul “*CNN-Based Ball and Goal Detection for KRSBI Robot with Omnidirectional Camera*” dilakukan oleh Farhan & Candra (2025). Penelitian ini berfokus pada pengembangan sistem deteksi bola dan gawang berbasis *computer vision* pada robot yang mengikuti Kompetisi Robot Sepak Bola Indonesia (KRSBI) Beroda menggunakan kamera *omnidirectional*. Metode tradisional seperti *HSV color filtering* sebelumnya banyak digunakan karena implementasinya sederhana, namun performanya sangat bergantung pada intensitas cahaya sehingga tidak stabil dalam kondisi pencahayaan yang bervariasi. Untuk mengatasi kelemahan tersebut, penelitian ini mengusulkan penerapan algoritma YOLO yang berbasis CNN guna meningkatkan akurasi dan keandalan deteksi objek secara *real-time*. Dataset yang digunakan terdiri dari 1.125 citra dengan variasi pencahayaan dan posisi objek yang berbeda, kemudian dibagi menjadi 80% data pelatihan dan 20% data validasi. Model YOLOv8 dilatih menggunakan *Ultralytics* di platform Google Colab selama 100 *epoch*. Hasil pelatihan menunjukkan performa deteksi yang sangat tinggi, dengan tingkat akurasi sebesar 95,87%, *precision* mencapai 1.00 pada *confidence threshold* 0.921, *recall* sebesar 0.99, dan nilai *F1-Score* maksimum 0.97 pada *confidence* 0.149. Berdasarkan kurva *precision–confidence*, model dapat menghasilkan deteksi tanpa *false positive* pada ambang kepercayaan tinggi, sedangkan kurva *recall–confidence* menunjukkan

kemampuan model mendeteksi hampir semua objek meskipun pada nilai *confidence* yang rendah. Hasil penelitian ini membuktikan bahwa model YOLOv8 berbasis CNN mampu memberikan solusi yang tangguh dan efisien untuk sistem deteksi bola dan gawang secara real-time pada robot sepak bola beroda. Selain itu, performa model menunjukkan tingkat stabilitas yang baik terhadap perubahan pencahayaan dan posisi objek, sehingga metode ini dinilai efektif untuk diterapkan pada sistem persepsi visual robot KRSBI Beroda.

Kedua, penelitian yang berjudul “Implementasi *Object Detection* pada Robot Sepak Bola Beroda Berbasis Kamera *Omnidirectional* Menggunakan Opencv” dilakukan oleh Nanda et al. (2023). Penelitian ini mengangkat permasalahan terkait sistem deteksi pada robot KRSBI yang masih sangat dipengaruhi oleh kondisi pencahayaan. Perubahan intensitas cahaya di lapangan membuat sistem kesulitan mempertahankan akurasi deteksi, sehingga kinerja robot menjadi tidak stabil ketika kondisi cahaya berubah. Metode yang digunakan dalam penelitian ini adalah *object detection* berbasis kamera *omnidirectional* dengan bantuan pustaka OpenCV. Proses pengujian dilakukan dengan cara mengukur variasi intensitas cahaya di lapangan untuk melihat pengaruhnya terhadap kemampuan deteksi objek. Hasil yang diperoleh menunjukkan bahwa robot KRSBI mampu mengenali beberapa objek penting, seperti bola, gawang, serta robot lawan (*cyan* dan *magenta*), dengan tingkat akurasi sekitar 70%. Akan tetapi, nilai akurasi ini masih cukup dipengaruhi oleh perbedaan intensitas cahaya dari masing-masing objek. Dengan demikian, penelitian ini membuktikan bahwa penerapan *object detection* menggunakan kamera *omnidirectional* dan OpenCV dapat berjalan pada robot KRSBI, namun tetap memiliki keterbatasan signifikan terutama ketika menghadapi kondisi pencahayaan yang tidak stabil.

Ketiga, penelitian yang berjudul “Perancangan Sistem Pendeteksian Obyek Bola dengan Metode *Framework* YOLO V4” dilakukan oleh Nuralim et al. (2022). Latar belakang penelitian ini berangkat dari kebutuhan dalam KRSBI Beroda tahun 2018, di mana robot dituntut mampu melakukan navigasi serta menjalankan tugas utama, yaitu menemukan bola, menggiringnya, dan menendangnya ke arah gawang lawan. Untuk dapat melaksanakan fungsi tersebut, robot membutuhkan sistem

pendeteksian bola yang cepat, akurat, dan responsif. Metode yang digunakan dalam penelitian ini adalah *object detection* berbasis *framework* YOLOv4. Pengujian sistem dilakukan menggunakan *confusion matrix* untuk mengukur performa deteksi, termasuk dalam kondisi ketika bola sebagian terhalang oleh objek lain. Hasil pengujian menunjukkan bahwa sistem mampu mendeteksi bola meskipun terdapat penghalang dengan tingkat persentase 50%, 60%, hingga 70%. Namun, kemampuan deteksi menurun drastis ketika tingkat penghalang mencapai 80% ke atas. Pada kondisi tersebut (80%, 90%, hingga 100% penghalang), robot tidak lagi dapat mengenali keberadaan bola. Penelitian ini membuktikan bahwa YOLOv4 cukup efektif dalam mendeteksi bola pada kondisi yang dinamis dan kompleks, termasuk ketika sebagian objek tertutup. Akan tetapi, keterbatasan tetap muncul pada tingkat *occlusion* yang tinggi, yang menunjukkan perlunya optimasi atau integrasi metode tambahan untuk meningkatkan keandalan deteksi dalam skenario pertandingan nyata.

Penelitian berikutnya dilakukan oleh Sholehurrohman et al. (2023) dengan judul “Analisis Metode *Kalman Filter*, *Particle Filter* dan *Correlation Filter* Untuk Pelacakan Objek” membahas mengenai tantangan dalam pelacakan objek (*object tracking*) pada bidang *computer vision*. Penelitian ini mengimplementasikan tiga metode, yaitu *Kalman Filter*, *Particle Filter*, dan *Correlation Filter* untuk pelacakan objek pada data video lalu lintas dan video sirkuit Nascar. Hasil penelitian menunjukkan bahwa metode *Kalman Filter* memiliki akurasi tertinggi mencapai 96,89%, sedangkan metode *Correlation Filter* lebih unggul dalam aspek performa komputasi dengan rata-rata 26,69 FPS, sementara *Particle Filter* berada di bawah *Kalman Filter* dalam hal akurasi. Kesimpulan dari penelitian ini menegaskan bahwa *Kalman Filter* sangat potensial digunakan dalam pelacakan objek yang membutuhkan akurasi tinggi, sementara *Correlation Filter* lebih sesuai untuk kebutuhan aplikasi *real-time* karena efisiensi komputasinya. Dengan demikian, penelitian ini dapat dijadikan acuan penting dalam mendukung pemanfaatan *Kalman Filter* pada penelitian terkait optimasi pergerakan robot sepak bola, khususnya dalam memprediksi pergerakan bola secara akurat.

Penelitian kelima berjudul “Implementasi Algoritma SIFT (*Scale-Invariant Feature Transform*) dan Algoritma *Kalman Filter* dalam Mendeteksi Objek Bola” yang dilakukan oleh C. Saputra (2023) berfokus pada pengembangan sistem pendeteksian bola pada robot KRSBI Beroda. Latar belakang penelitian ini adalah tuntutan agar robot mampu mendeteksi, melacak, serta menggiring bola menuju gawang lawan secara efektif dalam KRSBI Beroda. Metode pendeteksian berbasis *color filtering* sebelumnya memang dinilai cukup baik dalam mengidentifikasi objek, namun masih memiliki kelemahan dalam aspek pelacakan (*tracking*). Untuk mengatasi hal tersebut, penelitian ini menggabungkan algoritma SIFT yang berfungsi membandingkan fitur citra guna memastikan objek yang terdeteksi benar-benar bola, serta algoritma *Kalman Filter* yang berperan sebagai estimator dalam memprediksi arah pergerakan bola berdasarkan status objek pada *frame* sebelumnya. Hasil dari penelitian ini menunjukkan bahwa kombinasi algoritma SIFT dan *Kalman Filter* dapat meningkatkan akurasi serta kecepatan pendeteksian bola. *Tracking* yang dilakukan dengan *Kalman Filter* mampu memprediksi pergerakan objek dengan baik, di mana koordinat y akan semakin kecil jika bola bergerak ke atas *frame* dan semakin besar jika bergerak ke bawah, sedangkan koordinat x akan semakin kecil ketika bola bergerak ke kiri dan semakin besar saat bergerak ke kanan. Dari hasil pengujian, sistem berhasil mendeteksi objek bola dengan sempurna pada jarak tertentu, dengan rata-rata *error* pengukuran *Kalman Filter* sebesar 1,06 untuk koordinat x dan 7,34 untuk koordinat y . Dengan demikian, penelitian ini menegaskan potensi integrasi SIFT dan *Kalman Filter* untuk menghasilkan sistem deteksi dan pelacakan bola yang lebih andal dalam mendukung performa robot KRSBI.

Penelitian selanjutnya yang relevan berjudul “*Detection and Recognition of Moving Video Objects: Kalman Filtering with Deep Learning*” yang dilakukan oleh Mohammed & Hussain (2021). Penelitian ini bertujuan untuk meningkatkan akurasi dalam proses deteksi dan pengenalan objek bergerak dalam urutan video. Tujuan ini diangkat karena adanya faktor penghalang seperti jarak deteksi kamera atau kekaburan (*blurring*) gambar yang dapat mengurangi akurasi teknik yang ada. Untuk mencapai akurasi yang lebih tinggi, metode yang diusulkan adalah sistem

hibrida yang menggabungkan *Kalman Filter* dengan CNN. *Kalman Filter* diterapkan pada tahap awal deteksi untuk menghilangkan latar belakang dan memotong objek, serta berfungsi sebagai estimator rekursif yang mampu memprediksi lokasi objek di masa depan, mengurangi *noise* dari deteksi yang salah, dan mengasosiasikan multi-objek ke treknya. Setelah itu, model CNN akan memprediksi kategori objek yang sudah dideteksi dan dipotong. Hasil eksperimen menunjukkan bahwa pendekatan hibrida ini berhasil mencapai akurasi pengenalan hingga 100% pada 8 video berbeda. Hasil ini menunjukkan superioritas sistem yang diusulkan dibandingkan dengan enam algoritma lain yang ada.

Penelitian selanjutnya adalah studi berjudul "*Optimized Object Tracking Technique Using Kalman Filter*" yang dilakukan oleh Taylor et al. (2016). Penelitian ini berfokus pada pengembangan teknik pelacakan objek yang efisien untuk mengatasi masalah waktu pemrosesan yang tinggi dalam pendeteksian objek di tengah adegan yang berantakan (*cluttered scene*). Metode konvensional pelacakan berbasis fitur seperti SIFT atau SURF (*Speeded Up Robust Feature*) dinilai akurat, tetapi membutuhkan waktu pemrosesan yang lebih tinggi. Sebaliknya, metode berbasis warna memiliki waktu pemrosesan yang lebih cepat, namun akurasi yang terbatas. *Kalman Filter* digunakan dalam penelitian ini adalah untuk mengatasi kompromi tersebut dan meningkatkan efisiensi komputasi, khususnya untuk aplikasi *real-time* seperti pada sistem robotik. *Kalman Filter* berperan sebagai estimator rekursif yang efisien untuk memprediksi lokasi objek di *frame* berikutnya berdasarkan status saat ini dan model gerakan objek (diasumsikan kecepatan konstan). Prediksi lokasi ini memungkinkan sistem hanya mencari objek dalam jendela gambar yang dipotong (*cropped image*) yang ukurannya jauh lebih kecil daripada keseluruhan *frame* video. Dengan demikian, waktu pemrosesan pendeteksian objek dapat diminimalkan secara signifikan. Hasil dari penelitian ini menunjukkan bahwa integrasi *Kalman Filter* dengan teknik *cropping* secara signifikan mempercepat waktu pemrosesan sambil mempertahankan tingkat akurasi yang tinggi. Waktu pemrosesan menjadi lebih cepat ketika ukuran jendela pencarian (*search window*) diperkecil. Untuk menyeimbangkan antara waktu pemrosesan yang minimal dan kesalahan jarak (*distance error*) yang minimal,

penelitian ini menyimpulkan bahwa ukuran jendela pencarian yang optimal adalah 2.16 kali dimensi terbesar objek. Pada ukuran ini, terdapat penurunan signifikan dalam waktu pemrosesan sekaligus memastikan objek terdeteksi dengan tingkat keberhasilan yang tinggi, serta pusat objek yang terdeteksi cukup dekat dengan pusat sebenarnya.

Penelitian selanjutnya oleh Egi (2022), yang berjudul "*Basketball self training shooting posture recognition and trajectory estimation using computer vision and Kalman Filter*", secara khusus berfokus pada peningkatan performa *self-shooting* bola basket, terutama untuk pemain muda, yang sering mengalami kesulitan dan keengganan akibat postur yang salah dan tembakan yang meleset tanpa bimbingan pelatih. Penelitian ini dibuat sebagai upaya untuk menyediakan sistem umpan balik otomatis yang dapat melacak gerakan pemain, mengenali postur, dan mengestimasi lintasan proyektil secara *real-time*. Penelitian ini menggunakan teknik *computer vision* seperti pemisahan saluran warna RGB, *Median Filter*, binarisasi, dan *Area Opening* untuk mendeteksi serta melabeli objek penting, yaitu bola basket dan *T-shirt* pemain. Dengan mengestimasi lintasan proyektil, penelitian ini menunjukkan bahwa lintasan tersebut dipengaruhi secara signifikan oleh ketidakpastian lingkungan, khususnya gaya hambat udara (*air drag force*). Untuk mengatasi *noisy medium* (medium bising) ini dan mengoptimalkan lintasan yang sebenarnya, algoritma *Kalman Filter* digunakan sebagai filter rekursif canggih untuk memprediksi posisi, kecepatan, dan percepatan objek bergerak serta mengurangi kesalahan prediksi secara berulang. Hasilnya, penelitian ini berhasil menentukan bahwa sudut tembakan optimal (*best shooting angle*) yang menghasilkan skor sukses paling tinggi bagi pemain dengan tinggi 1.73 m dan kecepatan awal 9.5 m/s adalah 50° ketika gaya hambat udara diperhitungkan. Perhitungan ini menunjukkan deviasi yang signifikan; tanpa hambatan udara, jangkauan maksimum horizontal (x_{max}) adalah 10.76 m, namun dengan hambatan udara, x_{max} turun menjadi 5.47 m, menegaskan peran krusial *Kalman Filter* dalam memprediksi lintasan secara akurat dalam kondisi dunia nyata.

Penelitian selanjutnya adalah "*ConfTrack: Kalman Filter-based Multi-Person Tracking by Utilizing Confidence Score of Detection Box*" yang diteliti oleh

Jung et al. (2024). Urgensi penelitian ini muncul dari kelemahan mendasar *tracker* berbasis *Kalman Filter-based Tracking-by-Detection* (KFTBD) konvensional ketika dihadapkan pada hasil deteksi yang *noisy* (kotak dengan *confidence* rendah) dalam situasi ramai. Deteksi berkepercayaan rendah ini terbukti berhubungan dengan nilai *Intersection over Union* (IoU) yang lebih rendah, yang secara langsung mengganggu kinerja pelacakan dan berpotensi menyebabkan *ID switch* atau kegagalan *track*. Untuk mengatasi masalah ini, *ConfTrack* menyarankan peningkatan fungsi *Kalman Filter* yang adaptif terhadap skor kepercayaan. Fungsi utama *Kalman Filter* dalam penelitian ini tetap sebagai estimator yang memprediksi dan memperbarui status *track*, namun ditambahkan tiga metode utama untuk menanggulangi *noise*, yaitu *Confidence Weighted Kalman-Update* (CW) untuk melakukan modifikasi pada pengukuran target *Kalman Filter*. Jika skor kepercayaan deteksi rendah, pengukuran yang digunakan akan lebih condong ke prediksi *Kalman Filter* daripada ke deteksi mentah (*noisy*). Kemudian menggunakan *Noise Scale Adaptive Kalman Filter* (NK) untuk memperkuat kovariansi *noise* ruang pengukuran yang digunakan untuk menghitung *Kalman gain* ketika skor kepercayaan rendah. Hal ini secara efektif memberikan penalti pada deteksi berkepercayaan rendah di tahap *matching*. Terakhir, menggunakan *Constant Box Prediction* (CP) untuk menstabilkan prediksi *Kalman Filter* untuk *lost track* dengan mengatur variasi ukuran kotak menjadi nol, meminimalkan dampak *noise* pada prediksi dimensi kotak. Hasil penelitian menunjukkan bahwa kombinasi metode berbasis *Kalman Filter* ini, khususnya NK, memberikan kontribusi paling konsisten dalam menaikkan metrik pelacakan. *ConfTrack* terbukti paling kuat di lingkungan ramai dan berkinerja baik dalam berbagai situasi, mencapai skor *Higher Order Tracking Accuracy* (HOTA) dan *Identification F1-Score* (IDF1) tertinggi pada *dataset Multiple Object Tracking Benchmark 2020* (MOT20). Pencapaian IDF1 tertinggi menunjukkan bahwa *ConfTrack* sangat kuat terhadap *noise* deteksi di lingkungan ramai, memungkinkannya melacak secara stabil dengan tingkat *missing track* yang rendah dan menghasilkan *trajectory* yang stabil saat terjadi oklusi. Dengan demikian, penelitian ini menegaskan kembali

peran krusial *Kalman Filter* dalam *multi-person tracking*, khususnya melalui penyesuaian adaptif terhadap kualitas data input deteksi.

Penelitian yang terakhir adalah “*Automatic pear and apple detection by videos using deep learning and a Kalman Filter*” oleh Takura et al. (2021). Penelitian ini mengatasi tantangan krusial dalam otomatisasi pertanian, yaitu estimasi jumlah buah di kebun secara akurat. Proses penghitungan buah dibagi menjadi dua langkah penting: deteksi buah dan pelacakan buah (*tracking*) melalui urutan *frame* gambar. Urgensi pelacakan muncul karena kondisi lapangan yang tidak stabil, seperti perubahan pencahayaan di bawah kanopi pohon, serta kemungkinan buah tertutup oleh daun atau ranting (*occlusion*), yang dapat menyebabkan kegagalan deteksi di beberapa *frame*. Tanpa pelacakan yang andal, buah yang muncul kembali setelah tersembunyi dapat dihitung ganda (*double-counted*), sehingga hasil penghitungan menjadi tidak akurat. Untuk mengatasi masalah ini, metode deteksi objek berbasis *deep learning* YOLO v2 digunakan untuk mengidentifikasi buah di setiap *frame*. Kemudian, *Kalman Filter* diterapkan untuk pelacakan objek. Fungsi utama *Kalman Filter* adalah sebagai estimator yang memprediksi dan mengoreksi status (posisi dan kecepatan) buah yang sedang dilacak, bahkan ketika deteksi buah gagal di *frame* tersebut. Ini memastikan bahwa buah yang sama dapat terus diidentifikasi di *frame* yang berurutan, meskipun sempat tidak terdeteksi. Hasilnya menegaskan efektivitas integrasi ini: sistem berhasil menghitung buah pir dan apel secara otomatis dengan kesalahan absolut kurang dari 10%. Secara spesifik, dari total 234 buah pir, 226 buah berhasil dihitung dengan benar, menghasilkan nilai F1 sebesar 0.972. Performa *Kalman Filter* juga terbukti jauh lebih unggul dibanding algoritma pelacakan fitur Kanade-Lucas-Tomasi (KLT), yang menyebabkan penghitungan berlebih (*over-counted*). Dengan demikian, penelitian ini menunjukkan bahwa *Kalman Filter* sangat efektif dan esensial dalam menstabilkan proses penghitungan objek bergerak pada video di lingkungan yang tidak terkontrol.

Tabel 2.1 Penelitian Terdahulu

No	Peneliti	Tahun	Judul	Masalah	Metode	Hasil	Perbedaan
1	T. Mohd. Farhan, Feri Chandra	2024	<i>CNN-Based Ball and Goal Detection for KRSBI Robot with Omnidirectional Camera</i>	Metode deteksi objek tradisional seperti penyaringan warna HSV memiliki kinerja yang buruk di bawah variasi kondisi pencahayaannya pada robot KRSBI-Beroda	Menggunakan CNN berbasis algoritma YOLOv8 dengan kamera <i>omnidirectional</i> . Model dilatih menggunakan 1.125 gambar selama 100 epochs.	Model mencapai Akurasi 95,87%, Presisi 1.00 (pada confidence 0.921) 8, Recall 0.99, dan F1-Score 0.97 (pada confidence 0.149).	Penelitian ini fokus meningkatkan kinerja robot dari menggunakan HSV ke YOLO, sedangkan penelitian sekarang menambahkan optimasi gerakan dengan <i>Kalman Filter</i> .
2	Bagas Musamma Nanda, Simon Siregar, dan Muhammad Ikhsan Sani	2023	<i>Implementasi Object Detection pada Robot Sepak Bola Beroda Berbasis Kamera Omnidirectional</i>	Deteksi objek yang bergantung pada intensitas cahaya, sehingga membuat hasil deteksi menjadi kurang efektif	<i>OpenCV Object Detection</i>	Robot bisa deteksi bola, gawang, robot cyan & magenta dengan akurasi $\pm 70\%$, tapi hasil dipengaruhi intensitas cahaya.	Penelitian ini hanya menggunakan OpenCV sederhana, sedangkan penelitian sekarang memakai YOLO + <i>Kalman Filter</i> .

			Menggunakan Opencv				
3	Jalu Nuralim, Nifty Fath, Akhmad Musafa, Sujono, Drs. Suwasti Broto	2022	Perancangan Sistem Pendeteksian Obyek Bola dengan Metode <i>Framework</i> YOLO V4	Robot butuh deteksi cepat untuk navigasi & menendang bola, namun terhambat jika bola terhalang sebagian.	YOLOv4 + <i>Confusion Matrix</i>	Robot masih bisa deteksi bola hingga 70% tertutup, gagal pada >80%.	Fokus pada akurasi YOLOv4 dengan halangan, sedangkan penelitian sekarang menambahkan prediksi pergerakan menggunakan <i>Kalman Filter</i> .
4	Ridho Sholehurrohman, Mochammad Reza Habibi, Igit Sabda Ilman, Rahman Taufiq, Muhaqiqin	2023	Analisis Metode <i>Kalman Filter</i> , <i>Particle Filter</i> dan <i>Correlation Filter</i> Untuk Pelacakan Objek	<i>Tracking</i> objek sering gagal karena oklusi dan deformasi target.	<i>Kalman Filter</i> , <i>Particle Filter</i> , <i>Correlation Filter</i>	<i>Kalman Filter</i> akurasi 96,89%, <i>Correlation Filter</i> paling cepat 26,69 FPS.	Penelitian ini membandingkan metode tracking umum, penelitian sekarang fokus <i>Kalman Filter</i> untuk robot sepak bola berbasis YOLO.
5	M. Irwan Bustami, Chindra Saputra, Desi Kisbianty, Arjuna Panji Prakarsa	2023	Implementasi Algoritma SIFT (<i>Scale-Invariant Feature Transform</i>) dan <i>Kalman Filter</i> dalam	Metode <i>color filtering</i> saja kurang handal untuk <i>tracking</i> bola.	SIFT + <i>Kalman Filter</i>	SIFT mengenali objek, <i>Kalman Filter</i> memprediksi arah bola. <i>Error</i> rata-rata 1.06 (x) dan 7.34 (y).	Penelitian ini gabungkan SIFT + <i>Kalman Filter</i> , sedangkan penelitian sekarang pakai YOLO untuk deteksi dan <i>Kalman Filter</i> untuk prediksi.

Mendeteksi
Objek Bola

6	Hind Rustum Mohammed & Zahir M. Hussain	2021	<i>Detection and recognition of moving video objects: Kalman Filtering with deep learning</i>	Kebutuhan akan akurasi yang lebih tinggi dalam deteksi dan pengenalan objek bergerak, terutama menghadapi kendala seperti jarak kamera atau <i>blurring</i> gambar yang menyebabkan eror pada teknik yang sudah ada.	<i>Kalman Filter</i> untuk deteksi, penghilangan latar belakang, dan <i>tracking</i> . Kemudian CNN digunakan untuk pengenalan kategori objek.	Akurasi pengenalan mencapai 100% pada 8 video berbeda. Sistem menunjukkan superioritas dibandingkan enam algoritma yang ada.	Tujuan utama adalah deteksi dan pengenalan objek bergerak secara umum. <i>Kalman Filter</i> digunakan sebagai tahap awal untuk deteksi dan tracking. Metode deteksi awal tidak menggunakan YOLO, melainkan <i>Temporal Median</i> dan <i>thresholding</i> untuk menghilangkan <i>background</i> .
7	Liana Ellen Taylor, Midriem Mirdanies, Roni Permana Saputra	2016	<i>Optimized Object Tracking Technique Using Kalman Filter</i>	Waktu pemrosesan yang tinggi pada deteksi objek, terutama untuk aplikasi <i>real-time</i> , sambil	<i>Kalman Filter</i> (sebagai estimator/prediktor posisi) dikombinasikan dengan <i>Color Segmentation</i>	Proses pelacakan menjadi lebih cepat secara signifikan (waktu pemrosesan berkurang) dengan mempertahankan	Penelitian ini menggunakan Segmentasi Warna dan <i>Kalman Filter</i> untuk mengoptimalkan waktu pemrosesan melalui teknik <i>Cropped Image</i> .

mempertahankan akurasi dalam adegan yang berantakan (<i>cluttered scene</i>).	(untuk deteksi) dan teknik <i>Cropped Image</i> (pemotongan gambar) untuk membatasi area pencarian.	akurasi tinggi. Ukuran jendela pencarian optimal ditemukan pada 2.16 kali dimensi terbesar objek, menyeimbangkan waktu pemrosesan dan kesalahan jarak.	Sedangkan penelitian sekarang menggunakan YOLOv8 (model <i>deep learning</i> yang kompleks) sebagai detektor, dan <i>Kalman Filter</i> digunakan untuk stabilisasi <i>tracking</i> dan mengatasi oklusi/ <i>false negative</i> akibat beban komputasi YOLO yang tinggi. Fokus optimasi dalam penelitian ini adalah mengurangi area pencarian (<i>cropped image</i>), sementara penelitian sekarang adalah menstabilkan <i>output</i> detektor modern (YOLO).
---	---	--	--

8	Yunus Egi	2022	<i>Basketball self training shooting posture</i>	Kurangnya umpan balik dari pelatih membuat <i>self-shooting</i>	Menggunakan kombinasi <i>computer vision</i> tradisional (RGB	Sistem berhasil mengklasifikasikan objek dan menentukan sudut	Penelitian ini berfokus pada analisis postur manusia dan estimasi lintasan proyektil fisik
---	-----------	------	--	---	---	---	--

<i>recognition and trajectory estimation using computer vision and Kalman Filter</i>	menyulitkan dan memakan waktu, di mana postur salah menyebabkan tembakan meleset dan menimbulkan keengganan. Diperlukan algoritma untuk memberikan <i>feedback</i> postur dan lintasan <i>real-time</i> .	<i>Channelization</i> , Median Filter, Binarisasi, <i>Area Opening</i>) untuk deteksi <i>centroid</i> bola dan <i>T-shirt</i> . Dilanjutkan dengan <i>Kalman Filter</i> untuk mengoptimalkan dan mengoreksi prediksi lintasan proyektil di lingkungan bising (adanya gaya hambat udara)	postur terbaik. <i>Kalman Filter</i> terbukti penting karena tanpa hambatan udara (x_{max} 10.76 m), hasil berbeda signifikan dari kondisi nyata dengan hambatan udara (x_{max} 5.47 m), sehingga filter berhasil mengoreksi prediksi lintasan fisik. Sudut terbaik yang terdeteksi 51°.	(bola basket) dalam domain olahraga/biomekanika, menggunakan CV tradisional. <i>Kalman Filter</i> berfungsi untuk mengoreksi noise fisik (gaya hambat udara) pada lintasan. Penelitian sekarang berfokus pada optimasi gerakan robot dalam domain Robot Sepak Bola, menggunakan CV berbasis YOLOv8. <i>Kalman Filter</i> berfungsi untuk menstabilkan <i>noise</i> deteksi objek (oklusi/ <i>false negative</i>) dan mereduksi beban komputasi.
--	---	--	--	--

9	Hyeonchul Jung, Seokjun Kang,	2024	<i>ConfTrack: Kalman Filter-based Multi-</i>	Kegagalan <i>tracking</i> dan <i>ID switch</i> pada	Mengembangkan <i>tracker ConfTrack</i> berbasis <i>Kalman</i>	<i>ConfTrack</i> mencapai skor HOTA dan IDF1	<i>ConfTrack</i> berfokus pada <i>Multi-Person Tracking</i> di lingkungan
---	-------------------------------	------	--	---	---	--	---

Takgen Kim,
HyeongKi Kim

*Person
Tracking by
Utilizing
Confidence
Score of
Detection Box*

*tracker Kalman
FilterTBD
konvensional
yang disebabkan
oleh hasil
deteksi
(bounding box)
berkepercayaan
rendah (noisy
detections) di
lingkungan yang
ramai (crowd
circumstances)*

*FilterTBD dengan
penalti deteksi
berkepercayaan
rendah (melalui
Confidence
Weighted Kalman-
Update (CW) dan
Noise Scale
Adaptive Kalman
Filter (NK)) pada
Kalman Filter, dan
strategi cascading
matching baru
(LM) untuk
memanfaatkan
deteksi
berkepercayaan
rendah.*

tertinggi pada
dataset MOT20,
membuktikan
robustness yang
tinggi terhadap
noise deteksi di
lingkungan yang
padat.

ramai, sementara
penelitian sekarang
adalah *Single-Object
Tracking* (Bola) untuk
robot sepak bola.
ConfTrack
memodifikasi *Kalman
Filter* untuk
mempenalti/menghukum
deteksi berkepercayaan
rendah guna stabilitas
ID. Penelitian sekarang
menggunakan *Kalman
Filter* untuk
memprediksi pergerakan
bola secara stabil,
mengoptimasi gerakan
robot, dan mengurangi
beban komputasi pada
YOLO.

10	Kenta Itakura, Yuma Narita, Shuhei Noaki, & Fumiki Hosoi	2021	<i>Automatic pear and apple detection by videos using</i>	Penghitungan buah di kebun dari video sulit karena	YOLOv2 untuk deteksi objek, kemudian melakukan	Rata-rata presisi (<i>Average Precision</i>) deteksi pir dan apel tinggi	Penelitian ini fokus pada objek statis (buah) di lingkungan pertanian yang tidak terkontrol
----	---	------	---	---	---	--	--

*deep learning
and a Kalman
Filter*

perubahan
kondisi cahaya
yang cepat dan
tidak stabil, buah
dapat tertutup
daun/ranting
(*occlusion*). Ini
menyebabkan
kegagalan
deteksi di
beberapa *frame*
dan potensi
penghitungan
ganda.

pelacakan
menggunakan
Kalman Filter.

(0.97).
Penghitungan pir
benar: 226 dari
234 ($F1 = 0.972$).
Kalman Filter
mampu melacak
buah yang sempat
tidak terdeteksi
(*occluded*).

(pencahayaannya, oklusi,
pergerakan kamera
handheld), sedangkan
penelitian sekarang
fokus pada objek
dinamis (bola) yang
bergerak cepat oleh
robot di lingkungan
yang lebih terkontrol.
Kemudian fungsi
Kalman Filter di
penelitian ini untuk
mengatasi kegagalan
deteksi sesaat dan
mencegah *double-
counting*. Sedangkan
dalam penelitian
sekarang, *Kalman Filter*
digunakan untuk
optimasi gerakan robot
dan stabilisasi *computer
vision*.

Secara keseluruhan, tinjauan penelitian terdahulu menunjukkan adanya konsensus bahwa algoritma *deep learning* seperti YOLO unggul dalam akurasi deteksi objek, tetapi memiliki kerentanan terhadap isu *real-time* dan ketidakstabilan data (*noise*) yang krusial dalam sistem robotika dinamis. Penelitian sebelumnya telah membuktikan bahwa integrasi antara *tracker* berbasis filter dengan detektor berbasis vision mampu meningkatkan performa pelacakan. Secara spesifik, *Kalman Filter* (KF) telah terbukti menjadi pilihan optimal dalam berbagai konteks pelacakan (*tracking*), mulai dari objek bergerak cepat hingga objek yang terhalang (*occlusion*), karena sifatnya yang ringan secara komputasi dan efektif dalam mereduksi *noise* serta memprediksi posisi. Perbedaan mendasar yang menjadi celah penelitian ini terletak pada belum adanya implementasi yang terfokus pada optimasi gerakan robot secara keseluruhan pada KRSBI Beroda UNRI menggunakan kombinasi spesifik YOLOv8 sebagai detektor dan KF sebagai *tracker*. Dengan demikian, penelitian ini bertujuan untuk menjembatani celah tersebut dengan mengimplementasikan dan menguji secara kuantitatif efektivitas integrasi kedua metode tersebut untuk menghasilkan sistem kontrol gerak robot yang lebih stabil, efisien, dan kompetitif.

2.2. Kompetisi Robot Sepak Bola Beroda Indonesia


Salah satu ajang kompetisi robotik di Indonesia adalah Kontes Robot Indonesia atau lebih sering disebut dengan KRI. KRI diselenggarakan oleh Pusat Prestasi Nasional (PUSPRESNAS) dan Kementerian Pendidikan dan Kebudayaan Republik Indonesia. KRI merupakan acara yang diadakan setiap tahun dan diikuti oleh mahasiswa dari berbagai wilayah di Indonesia mulai dari Timur, Tengah dan Barat. KRI terbagi menjadi 6 kategori, yang salah satunya adalah Kontes Robot Sepak Bola Indonesia (KRSBI) Beroda (Nanda et al., 2023).

Kontes Robot Sepakbola Beroda Indonesia diadakan untuk meningkatkan keilmuan dan kreatifitas mahasiswa di bidang robotika. Di dalam kontes ini, mahasiswa dituntut untuk bisa mengembangkan kemampuan dalam mekanika, manufaktur, elektronika, pemrograman, *artificial intelligent*, *image processing*, komunikasi digital, dan strategi, sekaligus diperlukan pengembangan ke arah

disiplin, toleransi, sportifitas, kerjasama, saling menghargai, kontrol emosi dan kemampuan *softskill* lainnya (Kusumoputro et al., 2024).

2.3. Robot Sepak Bola Beroda

Dalam KRSBI Beroda, robot yang digunakan pada tahap ini merupakan robot yang sama seperti yang dipakai pada pertandingan tingkat nasional, dengan beberapa ketentuan khusus. Jumlah robot yang diizinkan adalah dua unit, yaitu Robot 1 (R1) dan Robot 2 (R2), keduanya bertipe robot penyerang. Adapun spesifikasi fisik robot diatur dengan ukuran proyeksi ke lantai minimal $30\text{ cm} \times 30\text{ cm}$ dan maksimal $52\text{ cm} \times 52\text{ cm}$, dengan tinggi robot antara 40 cm hingga 80 cm. Jika tinggi robot melebihi 60 cm, maka bagian tubuh robot di atas ketinggian tersebut harus berada dalam silinder berdiameter 25 cm. Berat maksimum robot ditetapkan 40 kg, sedangkan bentuk robot dibuat bebas selama sesuai regulasi, dan warna yang digunakan adalah hitam (Kusumoputro et al., 2024).



Gambar 2.1 Robot Sepak Bola Beroda

Robot yang digunakan dalam Kontes Robot Sepak Bola Indonesia (KRSBI) Beroda memiliki bentuk khas menyerupai kubus dengan berbagai komponen


penting yang berfungsi mendukung pergerakan serta kemampuan bermain sepak bola. Gambar 2.1 memperlihatkan salah satu contoh robot KRSBI Beroda yang dilengkapi dengan berbagai sistem pendukung.

Kamera *omnidirectional* ditempatkan di bagian atas robot dan berfungsi untuk mendeteksi objek seperti bola, gawang, maupun robot lawan. Konsep kamera *omnidirectional* adalah menangkap citra dari segala arah (depan, belakang, kiri, dan kanan) menggunakan teknik pantulan cermin cembung yang diarahkan ke bawah (Surya et al., 2025). Dengan cara ini, kamera mampu memperoleh citra lapangan secara menyeluruh hanya dari satu titik pengamatan. Robot dilengkapi dengan penendang berbasis solenoid. Solenoid adalah sebuah komponen elektromagnetik yang berfungsi mengubah energi listrik menjadi energi mekanis. Energi mekanis yang dihasilkan dapat berupa gerakan mendorong (*push*) maupun menarik (*pull*) (Shofi et al., 2023).

Pada bagian depan robot terdapat roda kecil yang dipasang motor penggerak dan berputar ke arah dalam tubuh robot. Roda ini berfungsi untuk menangkap dan menahan bola ketika robot bergerak, sehingga bola tetap berada di depan robot dan tidak mudah terlepas. Bagian terakhir adalah roda yang berfungsi sebagai sistem penggerak robot. Pada robot KRSBI Beroda digunakan tiga roda utama agar pergerakan lebih fleksibel. Setiap roda terdiri dari dua komponen, yaitu motor dengan kecepatan putar sekitar 500 rpm yang menjadi sumber tenaga penggerak, serta *omni-wheel* yang memungkinkan robot dapat bergerak bebas ke berbagai arah.

2.4. Convolutional Neural Network (CNN)

Convolutional Neural Network (CNN) adalah salah satu jenis jaringan saraf tiruan yang dirancang khusus untuk mengolah data dengan struktur topologi berbentuk *grid*. Contohnya adalah data deret waktu yang dapat direpresentasikan sebagai *grid* satu dimensi, serta data citra yang tersusun dalam *grid* piksel dua dimensi. Istilah *convolutional* pada CNN merujuk pada penggunaan operasi matematika konvolusi di dalam arsitekturnya. Operasi konvolusi ini merupakan bentuk khusus dari operasi linier yang digunakan sebagai pengganti perkalian matriks konvensional pada satu atau lebih lapisan jaringan (Wakhidah et al., 2023).



Gambar 2.2 Arsitektur CNN


Sumber : analyticsvidhya.com, 2022

Pada CNN, setiap neuron direpresentasikan dalam bentuk dua dimensi sehingga metode ini sangat sesuai untuk pengolahan data citra. Arsitektur CNN umumnya terdiri atas beberapa tahap utama, yaitu lapisan *input*, proses ekstraksi fitur, tahap klasifikasi, dan lapisan *output*. Tahap ekstraksi fitur tersusun dari sejumlah lapisan tersembunyi yang meliputi lapisan konvolusi, fungsi aktivasi ReLU, serta lapisan *pooling*. Proses kerja CNN bersifat hierarkis, di mana keluaran dari lapisan konvolusi awal akan menjadi masukan bagi lapisan konvolusi berikutnya untuk mengekstraksi fitur yang semakin kompleks. Selanjutnya, pada tahap klasifikasi digunakan lapisan *fully connected* yang dipadukan dengan fungsi aktivasi *softmax* untuk menghasilkan keluaran berupa kelas atau label objek yang dikenali (Romario & Kadarina, 2020).

2.5. Algoritma YOLOv8 (*You Only Look Once version 8*)

YOLO merupakan salah satu model deteksi objek yang dikembangkan berdasarkan arsitektur *Convolutional Neural Network* (CNN). Model ini menerapkan pendekatan deteksi objek modern yang memungkinkan proses pendeteksian dilakukan secara *real-time*. Pada proses pengolahan citra, YOLO memiliki alur kerja yang relatif sederhana, di mana citra masukan terlebih dahulu diubah ukurannya agar sesuai dengan kebutuhan model. Selanjutnya, citra tersebut diproses menggunakan satu jaringan konvolusional secara menyeluruh untuk memprediksi lokasi dan kelas objek. Hasil deteksi kemudian diseleksi

menggunakan nilai ambang batas (*threshold*) berdasarkan tingkat kepercayaan (*confidence*) yang dihasilkan oleh model (Redmon et al., 2016).



Gambar 2.3 Ilustrasi Algoritma YOLO


Sumber : Redmon et al., (2016)

YOLOv8 merupakan evolusi baru dalam seri algoritma deteksi objek *You Only Look Once* (YOLO) yang dikembangkan oleh Ultralytics pada tahun 2023. Sebagai penerus dari versi sebelumnya, model ini dibangun di atas fondasi yang diletakkan oleh YOLOv5 dengan mengintegrasikan berbagai inovasi arsitektur dan metodologis yang signifikan. Secara konseptual, YOLOv8 menyatukan tugas lokalisasi objek dan klasifikasi ke dalam satu kerangka kerja jaringan saraf yang dapat didiferensiasikan secara *end-to-end*, mempertahankan karakteristik utama seri YOLO yang menyeimbangkan kecepatan dan akurasi. Penelitian memosisikan YOLOv8 sebagai solusi *state-of-the-art* dalam bidang visi komputer yang terus berkembang, menawarkan penyempurnaan yang menekankan pada peningkatan akurasi model serta kegunaan praktis untuk tugas deteksi objek secara *real-time* (Yaseen, 2024).

2.6. Robot Operating System (ROS)

Robot Operating System (ROS) merupakan sebuah sistem operasi robot yang bersifat *open-source*. Namun, penting untuk dipahami bahwa ROS bukanlah sistem

operasi dalam pengertian tradisional yang menangani manajemen proses dan penjadwalan seperti Windows atau Linux. Sebaliknya, ROS berfungsi sebagai lapisan komunikasi terstruktur (*structured communications layer*) yang berjalan di atas sistem operasi *host* pada kluster komputasi yang heterogen. ROS menyediakan kerangka kerja yang fleksibel untuk penulisan perangkat lunak robot, yang mencakup berbagai *tools* dan pustaka (*libraries*) yang bertujuan untuk menyederhanakan tugas pembuatan perilaku robot yang kompleks dan kuat di berbagai platform robotik (Quigley et al., 2009).



Gambar 2.4 ROS (*Robot Operating System*)


Sumber : Louda et al., (2023)

Pengembangan ROS dilatarbelakangi oleh tantangan besar dalam penulisan perangkat lunak untuk robot, di mana skala dan cakupan robotika terus berkembang pesat. Berbagai jenis robot memiliki perangkat keras yang sangat bervariasi, membuat penggunaan ulang kode (*code reuse*) menjadi hal yang tidak trivial. Selain itu, besarnya ukuran kode yang diperlukan sering kali melampaui kemampuan peneliti tunggal, sehingga diperlukan arsitektur yang mendukung upaya integrasi perangkat lunak berskala besar. ROS dirancang untuk menjawab tantangan spesifik yang ditemui saat mengembangkan robot layanan berskala besar sebagai bagian dari proyek STAIR (*STanford AI Robot*) di Stanford University dan Program Robot

Personal di Willow Garage. Meskipun bermula dari domain robot layanan dan manipulasi seluler, arsitektur yang dihasilkan bersifat jauh lebih umum dan dapat diterapkan pada berbagai sistem robotik lainnya (Quigley et al., 2009).

Secara teknis, implementasi ROS berpusat pada konsep *nodes*, *messages*, *topics*, dan *services*. *Node* adalah proses yang melakukan komputasi. Komunikasi antar *node* terjadi dengan mengirimkan *messages* (struktur data yang diketik secara ketat). Pengiriman pesan ini umumnya menggunakan mekanisme *publish-subscribe* melalui *topic*, di mana sebuah *node* mempublikasikan pesan ke topik tertentu dan *node* lain yang berlangganan topik tersebut akan menerimanya. Selain itu, untuk transaksi sinkron, ROS menyediakan mekanisme *service* yang berbasis permintaan dan respons (*request-response*) (Quigley et al., 2009).

2.7. OpenCV v3.4 (*Open Source Computer Vision version 3.4*)



Gambar 2.5 Kegunaan OpenCV

Sumber : [geeksforgeeks.org](https://www.geeksforgeeks.org/opencv/), 2025

OpenCV (*Open Source Computer Vision*) adalah sebuah pustaka perangkat lunak yang dirancang khusus untuk pengolahan citra secara *real-time*. Pustaka ini awalnya dikembangkan oleh Intel dan kini didukung oleh Willow Garage serta Itseez. OpenCV didistribusikan dengan lisensi BSD yang bersifat permisif, sehingga lebih fleksibel dibandingkan GPL dan dapat digunakan secara bebas, termasuk untuk kepentingan komersial tanpa kewajiban membuka kode sumber. Selain itu, OpenCV menyediakan antarmuka yang kompatibel dengan berbagai bahasa pemrograman seperti C++, C, Python, dan Java, serta dapat dijalankan pada

beragam sistem operasi, di antaranya Windows, Linux, Mac OS, iOS, dan Android. Pustaka ini dirancang untuk efisiensi komputasi dengan fokus utama pada aplikasi berbasis real-time (C. Saputra, 2023).

Modul pustaka OpenCV dirancang dengan tingkat fleksibilitas dan ketangguhan yang tinggi untuk menangani berbagai permasalahan dalam bidang *computer vision*. Berbagai solusi telah tersedia di dalamnya, seperti pemotongan citra (*cropping*), peningkatan kualitas citra melalui penyesuaian kecerahan, ketajaman, dan kontras, pendeteksian bentuk, segmentasi citra, pelacakan objek bergerak, hingga pengenalan objek, serta beragam fungsi lainnya (Ratna, 2020).

2.8. NumPy v2.3 (*Numerical Python version 2.3*)

NumPy (*Numerical Python*) adalah paket dasar dan fundamental untuk komputasi ilmiah dengan Python. Sebagai pustaka *open-source*, NumPy menyediakan objek *array* N-dimensi (*ndarray*) yang sangat kuat, yang berfungsi sebagai struktur data universal untuk pertukaran data multi-dimensi dalam ekosistem ilmiah Python. Objek *ndarray* ini memungkinkan operasi yang cepat dan efisien pada data homogen (semua elemen harus bertipe data yang sama) dalam jumlah besar, sebuah keunggulan signifikan dibandingkan list bawaan Python, yang dicapai melalui inti kode yang dioptimalkan dalam bahasa C. Selain struktur array multidimensi, NumPy juga menawarkan koleksi lengkap fungsi matematika tingkat tinggi, termasuk aljabar linear, transformasi Fourier, dan kemampuan angka acak, menjadikannya standar *de-facto* untuk komputasi *array* dan menjadi fondasi bagi pustaka ilmu data dan *machine learning* lainnya (NumPy, 2025).



Gambar 2.6 Logo NumPy

Sumber : python.plainenglish.io, 2025

NumPy berfungsi untuk melakukan operasi vektor matriks dengan mengolah *array* dan *array* multidimensi. NumPy juga dapat digunakan untuk kebutuhan dalam analisis data (Admaja, 2021).

2.9. Root Mean Square Error (RMSE)

Root Mean Square Error (RMSE) adalah metode pengukuran yang menghitung akar kuadrat dari rata-rata kuadrat selisih antara nilai prediksi (\hat{y}) dan nilai observasi aktual atau ground truth (y). Menurut Hodson (2022), RMSE merupakan metrik yang optimal untuk mengevaluasi model yang memiliki distribusi *error* bersifat normal atau Gaussian. Hal ini relevan dengan algoritma *Kalman Filter* yang secara teoritis bekerja dengan asumsi *noise* berdistribusi normal (Gaussian).

Karakteristik utama RMSE adalah sensitivitasnya terhadap kesalahan yang besar (*outliers*). Karena selisih *error* dikuadratkan sebelum dirata-ratakan, kesalahan besar akan memberikan penalti yang lebih berat dibandingkan kesalahan kecil (Hodson, 2022). Dalam konteks robotika sepak bola, karakteristik ini penting karena kesalahan posisi yang ekstrem (misalnya robot kehilangan jejak bola) dianggap jauh lebih fatal daripada deviasi kecil yang konsisten.

Secara matematis, RMSE dirumuskan sebagai berikut (Hodson, 2022):

$$\text{RMSE} = \sqrt{\frac{1}{n} \sum_{i=1}^n (\hat{y}_i - y_i)^2}$$

Keterangan:

n : Jumlah sampel data atau *frame*

\hat{y}_i : Nilai posisi hasil prediksi *Kalman Filter* pada frame ke- i .

y_i : Nilai posisi aktual (*ground truth*) pada frame ke- i .

Untuk mengukur efektivitas sistem pelacakan objek dan kualitas prediksi yang dihasilkan oleh algoritma *Kalman Filter*, diperlukan metode evaluasi statistik yang objektif. Salah satu metrik standar yang paling umum digunakan dalam pengukuran akurasi model adalah RMSE (Hodson, 2022).

2.10. *Kalman Filter*

Kalman Filter merupakan algoritma yang sangat kuat untuk memperkirakan keadaan suatu sistem dinamis berdasarkan serangkaian pengukuran yang tidak lengkap dan mengandung *noise*. Algoritma ini dikembangkan oleh Rudolf E. Kálmán, dan awalnya digunakan dalam bidang navigasi penerbangan. Namun, seiring waktu, *Kalman Filter* menjadi komponen penting di berbagai bidang, seperti robotika, ekonomi, dan terutama *computer vision* (CV). *Kalman Filter* bekerja melalui dua tahap utama yang berlangsung secara berulang, yaitu tahap prediksi dan tahap pembaruan (koreksi). Pada tahap pertama, sistem memperkirakan keadaan berikutnya beserta tingkat ketidakpastiannya. Kemudian, pada tahap pembaruan, hasil prediksi tersebut diperbaiki dengan memasukkan data pengukuran terbaru. Melalui proses ini, *Kalman Filter* mampu menghasilkan estimasi keadaan objek, seperti posisi dan kecepatannya, secara halus, akurat, dan stabil, meskipun data sensor yang diterima tidak sempurna (Ultralytics, 2025).

Kalman Filter dinamai dari penciptanya, Rudolf Kalman. Algoritma ini bekerja dengan menerima sejumlah data yang mengandung *noise*, kemudian menyaringnya untuk meminimalkan gangguan tersebut. Karena dirancang pada ruang *linear*, *Kalman Filter* juga dikenal dengan istilah *linear quadratic estimation* (Sholehurrohman et al., 2023). Metode *Kalman Filter* menggunakan informasi dari objek yang terdeteksi di suatu *frame* dan status objek dari *frame* sebelumnya untuk mendapatkan status yang baru dari objek tersebut (C. Saputra, 2023).

Dalam konteks AI, *Kalman Filter* banyak digunakan dalam sistem pelacakan objek (*object tracking*). Setelah model deteksi seperti Ultralytics YOLO berhasil mengidentifikasi objek pada suatu *frame*, *Kalman Filter* digunakan untuk memperkirakan posisi objek pada *frame* berikutnya. Perkiraan ini didasarkan pada model gerak (*motion model*), yang umumnya mengasumsikan bahwa objek bergerak dengan kecepatan atau percepatan konstan (Ultralytics, 2025).

Ketika *frame* berikutnya diterima, model deteksi memberikan hasil pengukuran baru berupa koordinat *bounding box* objek. *Kalman Filter* kemudian menjalankan tahap pembaruan (*update*), yaitu memperbaiki hasil prediksi awal

berdasarkan data baru tersebut. Proses ini sangat efektif karena beberapa alasan penting:

- Reduksi *noise*: *Kalman Filter* mampu menghaluskan hasil deteksi yang bergetar atau tidak stabil, sehingga jalur pelacakan menjadi lebih halus dan konsisten.
- Penanganan *occlusion*: Saat objek tidak terdeteksi selama beberapa *frame* (misalnya tertutup oleh benda lain), *Kalman Filter* tetap dapat memperkirakan posisinya. Dengan demikian, ketika objek muncul kembali, sistem dapat langsung mengenalinya tanpa kehilangan jejak.
- Estimasi keadaan (*state estimation*): Selain posisi, *Kalman Filter* juga mampu memperkirakan parameter lain seperti kecepatan dan arah gerak objek, sehingga memberikan pemahaman yang lebih menyeluruh tentang pergerakan objek.

Kemampuan *Kalman Filter* untuk memproses data secara rekursif dan efisien secara komputasi membuatnya sangat cocok untuk aplikasi *real-time*. Banyak algoritma pelacakan modern seperti SORT (*Simple Online and Realtime Tracking*) dan ByteTrack menggunakan *Kalman Filter* sebagai komponen inti prediksi geraknya. Bahkan, model Ultralytics terbaru seperti YOLO11 juga memanfaatkan pendekatan ini dalam mode pelacakannya (Ultralytics, 2025).

Selain *Kalman Filter* standar, terdapat beberapa varian dan metode turunan yang dikembangkan untuk menangani sistem dengan karakteristik yang lebih kompleks.

- *Extended Kalman Filter* (EKF): Merupakan pengembangan dari *Kalman Filter* klasik yang dirancang untuk menangani sistem non-linear. Jika *Kalman Filter* standar hanya bekerja optimal pada sistem linear, EKF mengatasinya dengan cara melakukan *linearization* terhadap model sistem di setiap langkah waktu. Dengan pendekatan ini, EKF mampu memberikan estimasi keadaan objek yang tetap akurat meskipun hubungan antarvariabel dalam sistem tidak bersifat linear, seperti pada kasus kendaraan yang berbelok atau robot yang bergerak dengan lintasan melengkung.

- *Unscented Kalman Filter* (UKF): Untuk sistem yang sangat non-linear, proses *linearization* pada EKF sering kali tidak cukup akurat. UKF hadir sebagai solusi yang lebih presisi dan stabil, dengan menggunakan pendekatan *unscented transform*. Metode ini tidak membutuhkan perhitungan turunan Jacobian, melainkan menggunakan sejumlah *sigma points* yang merepresentasikan distribusi keadaan secara lebih realistis sehingga hasil estimasi menjadi lebih akurat.
- *Particle Filter*: Selain kedua varian tersebut, terdapat juga metode *Particle Filter*, yang digunakan pada sistem non-linear dan non-Gaussian. Berbeda dengan *Kalman Filter* yang berasumsi distribusi Gaussian, *Particle Filter* merepresentasikan distribusi probabilitas dengan sekumpulan sampel acak (partikel). Metode ini banyak digunakan dalam robotika, khususnya untuk lokalisasi dan pemetaan, karena kemampuannya menangani ketidakpastian yang kompleks.

Dalam penerapannya, berbagai framework modern telah menyediakan implementasi *Kalman Filter*. Misalnya, *Ultralytics framework* menggunakan *Kalman Filter* dalam algoritma *object tracking*, sementara pustaka *OpenCV* juga menyediakan modul *Kalman Filter* yang banyak digunakan untuk pelacakan objek secara *real-time* dalam aplikasi *computer vision* (Ultralytics, 2025).

Secara sederhana, berikut merupakan persamaan matematika algoritma *Kalman Filter* pada persamaan berikut (Yuztiawan & Utaminingrum, 2017):

$$\hat{X}_{\bar{k}} = K_k \cdot Z_k + (1 - K_k) \cdot \hat{X}_{k-1}$$

Keterangan:

$\hat{X}_{\bar{k}}$: Estimasi saat ini

K_k : *Kalman Gain*

Z_k : Nilai dari hasil pendeteksian prediksi

\hat{X}_{k-1} : Estimasi sebelumnya

Kalman Filter beroperasi sebagai estimator jenis *predictor-corrector* yang bekerja dalam dua langkah utama: Prediksi dan Pembaruan. Tujuannya adalah untuk memberikan estimasi keadaan sistem (X) yang optimal dengan

meminimalkan kovariansi *error*, terutama saat berhadapan dengan nilai yang bising (*noisy*).

Langkah prediksi menggunakan estimasi keadaan dari langkah waktu sebelumnya ($k - 1$) untuk memproyeksikan atau memprediksi keadaan sistem saat ini (X_k^-).

- Tujuan: Memperkirakan di mana sistem akan berada pada langkah waktu k berdasarkan dinamika sistem yang diketahui dan input kontrol yang diterapkan.
- Proses: Filter memproyeksikan mean keadaan (X) dan kovariansi keadaan (P) dari langkah waktu sebelumnya ke langkah waktu saat ini.
- Kovariansi: Dalam proses prediksi, ketidakpastian (diwakili oleh kovariansi P) diperbesar oleh *noise* proses (Q).

Fungsi `kf_predict` menghitung mean keadaan (X) dan kovariansi (P) yang diprediksi.

```
from numpy import dot

def kf_predict(X, P, A, Q, B, U):
    # Prediksi Keadaan:  $X = (A * X_{sebelum}) + (B * U)$ 
    X = dot(A, X) + dot(B, U)

    # Prediksi Kovariansi:  $P = (A * P_{sebelum} * A.T) + Q$ 
    P = dot(A, dot(P, A.T)) + Q

    return(X,P)
```

Kode 2.1 Contoh kode prediksi *Kalman Filter* dengan NumPy

Setelah prediksi selesai, langkah pembaruan menggunakan nilai yang baru (Y_k) untuk mengoreksi prediksi tersebut.

- Tujuan: Menghitung estimasi akhir yang diperbarui untuk keadaan (X_k) dan kovariansi (P_k) pada langkah waktu k setelah melihat pengukuran.
- Residual/Inovasi (V_k): Langkah pertama adalah menghitung residual atau inovasi. Ini adalah perbedaan antara pengukuran aktual (Y_k) dan pengukuran yang diprediksi (berdasarkan keadaan yang diprediksi (X_k^-)).
- *Kalman Gain* (K_k): Residual ini kemudian dikalikan dengan *Kalman Gain* (K_k). *Kalman Gain* bertindak sebagai "berat" (*weight*) yang menentukan

seberapa besar prediksi harus dikoreksi oleh pengukuran baru. *Gain* ini mempertimbangkan kovariansi prediksi (P_k^-) dan kovariansi *noise* pengukuran (R_k).

- Jika noise pengukuran (R) tinggi, *gain* akan kecil, artinya filter lebih memercayai prediksinya sendiri.
- Jika kovariansi prediksi (P^-) tinggi (ketidakpastian prediksi besar), *gain* akan besar, artinya filter lebih memercayai pengukuran baru.
- Koreksi: Hasil koreksi ini ditambahkan ke keadaan yang diprediksi (X_k^-) untuk mendapatkan estimasi keadaan akhir (X_k). Kovariansi juga diperbarui (P_k) untuk mencerminkan ketidakpastian yang telah berkurang.

Fungsi `kf_update` menghitung *gain* dan mengoreksi *mean* (X) serta kovariansi (P).

```
from numpy import dot, linalg
from numpy.linalg import inv

def kf_update (X, P, Y, H, R):
    # Mean Prediksi Pengukuran (IM):  $H * X_{prediksi}$ 
    IM = dot(H, X)
    # Kovariansi Prediksi Pengukuran (IS):  $H * P_{prediksi} * H.T + R$ 
    IS = dot(H, dot(P, H.T)) + R

    # Kalman Gain (K):  $P_{prediksi} * H.T * inv(IS)$ 
    K = dot(P, dot(H.T, inv(IS)))

    # Pembaruan Keadaan:  $X_{baru} = X_{prediksi} + K * (Y - IM)$ 
    X = X + dot(K, (Y - IM))
    # Pembaruan Kovariansi:  $P_{baru} = P_{prediksi} - K * IS * K.T$ 
    P = P - dot(K, dot(IS, K.T))

    # ... (kode lain untuk menghitung LH/likelihood)
    return (X, P, K, IM, IS, LH) # Mengembalikan mean dan kovariansi yang diperbarui
```

Kode 2.2 Contoh kode perbaruan *state Kalman Filter* dengan NumPy

BAB III

METODOLOGI PENELITIAN

3.1. Metode Penelitian

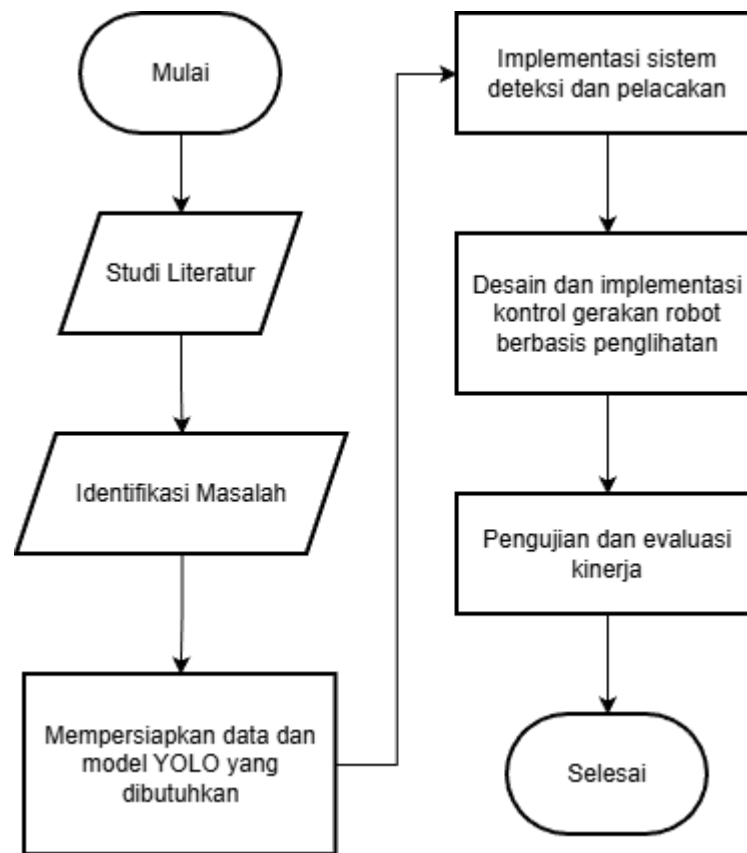
Penelitian ini menggunakan pendekatan kuantitatif dengan strategi eksperimental (*Experimental Research*). Pendekatan ini dipilih karena tujuan utama penelitian adalah untuk mengukur dan membandingkan secara objektif efektivitas sistem deteksi objek murni berbasis YOLO (*baseline*) dengan sistem yang dioptimasi menggunakan *Kalman Filter* (YOLO-KF) (*optimized*).

Data yang dikumpulkan akan bersifat numerik, mencakup metrik akurasi pelacakan seperti *Error* Estimasi (RMSE) dan *Error* Pelacakan Jarak, serta metrik kualitas gerakan robot seperti Stabilitas Gerakan (*Jerkiness Reduction*), Kecepatan Respons (*Latency*), dan Tingkat Keberhasilan *Re-acquire* Pasca-*Occlusion*. Data kuantitatif ini penting untuk melakukan analisis komparatif dan membuktikan sejauh mana *Kalman Filter* mampu mengoptimalkan gerakan robot Sepak Bola Beroda.

Strategi eksperimental akan dilakukan melalui implementasi langsung pada Robot Sepak Bola Beroda milik tim KRSBI UNRI. Pengujian akan mencakup skenario dinamis seperti Gerak Bola Konstan, Gerak Bola Mendadak (*High Acceleration*), dan *Occlusion* Sesaat. Perbedaan kinerja yang dihasilkan antara kelompok kontrol (*baseline*) dan kelompok eksperimen (*optimized*) dalam skenario-skenario ini akan menjadi dasar untuk menyimpulkan efektivitas implementasi *Kalman Filter* dalam sistem kontrol gerak berbasis penglihatan.

3.2. Kerangka Pikiran

Pada penelitian ini akan dilakukan beberapa tahap yang digambarkan pada gambar 3.1, yaitu dimulai dengan studi literatur, lalu mengidentifikasi masalah, mempersiapkan data dan model YOLO yang dibutuhkan, implementasi sistem deteksi dan pelacakan, desain dan implementasi kontrol gerakan robot berbasis penglihatan, pengujian dan evaluasi kinerja, dan selesai.



Gambar 3.1 Kerangka Pikiran Penelitian

3.3. Studi Literatur

Tahap studi literatur dalam metodologi penelitian ini bertujuan untuk mengumpulkan, menganalisis, dan mensintesis informasi teoretis dan praktis yang relevan dan dibutuhkan untuk perancangan serta implementasi sistem optimasi gerakan robot. Proses ini memastikan bahwa metode yang dipilih, khususnya integrasi YOLO dan *Kalman Filter*, didasarkan pada prinsip-prinsip teknis yang solid dan terkini.

Studi literatur difokuskan pada tiga area utama yang secara langsung mendukung perancangan sistem:

3.3.1. Algoritma Deteksi Objek

Mengidentifikasi model YOLO yang paling sesuai untuk kebutuhan *real-time* dengan keterbatasan komputasi pada robot KRSBI Beroda, yaitu YOLOv8. Kemudian mempelajari format *output* data deteksi dari YOLO (koordinat pusat x ,

y , lebar w , dan tinggi h *bounding box*) untuk dikonversi menjadi *input* data pengukuran yang dapat diproses oleh *Kalman Filter*.

3.3.2. Algoritma Prediksi dan Pelacakan

Mengkaji prinsip dasar *Kalman Filter*, terutama dalam konteks pelacakan objek bergerak (*object tracking*). Kemudian mempelajari implementasi *Kalman Filter* menggunakan pustaka yang efisien, seperti NumPy dan modul yang tersedia pada OpenCV atau Ultralytics untuk memastikan kompatibilitas dan efisiensi komputasi *real-time*.

3.3.3. Sistem Robotika dan Kontrol Gerak

Mempelajari spesifikasi teknis Robot Sepak Bola Beroda, khususnya mengenai sistem penglihatan (kamera *omnidirectional*) dan aktuator yang menentukan batasan dan kemampuan sistem kontrol gerak. Kemudian mengumpulkan informasi mengenai konversi data posisi terprediksi (*output Kalman Filter*) menjadi perintah gerakan yang akan dieksekusi oleh robot.

3.4. Identifikasi Masalah

Identifikasi masalah ini berasal dari celah (*gap*) antara metode deteksi berbasis YOLO yang memiliki beban komputasi tinggi dan kebutuhan akan gerakan robot yang stabil dan *real-time*. Masalah-masalah teknis yang perlu dipecahkan dalam penelitian ini meliputi:

3.4.1. Ketidakstabilan Data Deteksi Akibat Keterbatasan Komputasi (*Frame Rate Issue*)

Model deteksi YOLO (misalnya YOLOv8) membutuhkan kapasitas komputasi yang tinggi. Keterbatasan perangkat keras pada robot KRSBI Beroda seringkali menyebabkan penurunan *frame rate* atau keterlambatan proses inferensi. Masalah ini menghasilkan data posisi bola yang tidak stabil atau terlambat diterima oleh sistem kontrol, yang pada akhirnya mengakibatkan pergerakan robot menjadi tidak mulus atau tidak responsif.

3.4.2. Kerentanan Terhadap *Occlusion* dan *False Negative Detection*

Pada kondisi pertandingan yang dinamis, sering terjadi *occlusion* (bola tertutup sebagian) yang menyebabkan *false-negative detection* (bola tidak

terdeteksi). Tanpa mekanisme prediksi, robot akan berhenti bergerak atau kehilangan jejak bola saat *occlusion* sesaat terjadi, menghambat kontinuitas permainan.

3.4.3. Kebutuhan untuk Prediksi Posisi Gerak Dinamis

Detektor berbasis *frame* tunggal (YOLO) hanya memberikan posisi bola saat ini tanpa mempertimbangkan dinamika gerak bola tersebut. Untuk mengoptimalkan gerakan robot yang responsif terhadap perubahan posisi bola yang cepat dan mendadak, dibutuhkan sebuah mekanisme prediksi yang mampu mengestimasi posisi bola di *frame* berikutnya.

Tiga masalah teknis di atas akan diselesaikan melalui implementasi dan integrasi *Kalman Filter* pada *output* deteksi YOLO. *Kalman Filter* berperan sebagai estimasi rekursif untuk memprediksi posisi, menghaluskan data yang bising (*noisy*), dan mengatasi data yang hilang (*occlusion*).

3.5. Persiapan Data dan Konfigurasi Model Deteksi

Model deteksi yang digunakan dalam penelitian ini telah dilatih sebelumnya menggunakan kumpulan data citra yang diambil langsung dari kamera *omnidirectional* robot KRSBI. *Dataset* ini dikumpulkan untuk merepresentasikan berbagai variasi pencahayaan dan posisi bola di lapangan, guna memastikan model memiliki ketahanan terhadap perubahan lingkungan. Proses pra-pemrosesan data melibatkan pemberian label (*labelling*) pada objek bola menggunakan *bounding box*. Keluaran dari proses pelabelan ini menghasilkan koordinat *ground truth* yang kemudian digunakan untuk pelatihan model *deep learning*.

Model yang dipilih adalah arsitektur YOLOv8, diimplementasikan menggunakan *framework* Ultralytics. Pemilihan YOLOv8 didasarkan pada keunggulannya dalam memberikan keseimbangan optimal antara kecepatan inferensi dan akurasi, yang sangat penting untuk mencapai kinerja *real-time* pada robot dengan sumber daya komputasi terbatas. Model ini bertanggung jawab untuk menghasilkan prediksi lokasi bola yang kemudian menjadi input bagi algoritma pelacakan *Kalman Filter*.

Setelah model YOLOv8 berhasil mendeteksi bola, data hasil deteksi diekstraksi. Data ini berbentuk bounding box dengan format (x_c, y_c, w, h, C) , di mana (x_c, y_c) adalah koordinat pusat bola pada citra, dan C adalah *confidence score*. Koordinat pusat (x_c, y_c) inilah yang dijadikan Vektor Pengukuran (Z_k) yang bising (*noisy*) dan siap diolah lebih lanjut oleh *Kalman Filter*. *Confidence score* juga dapat dimanfaatkan untuk memverifikasi keandalan pengukuran saat proses pembaruan (koreksi) pada *Kalman Filter*.

3.6. Implementasi Sistem Deteksi dan Pelacakan

Sistem ini mengadopsi arsitektur *Tracking-by-Detection* di mana model YOLOv8 berfungsi sebagai detektor objek yang menghasilkan *measurement* (pengukuran), dan *Kalman Filter* berfungsi sebagai *tracker* (pelacak) yang melakukan prediksi dan koreksi. Keluaran dari YOLO berupa koordinat pusat bola (x_c, y_c) pada setiap *frame* digunakan sebagai input pengukuran (Z_k) yang bising ke *Kalman Filter*. *Kalman Filter* kemudian menjalankan siklus prediksi dan pembaruan untuk menghasilkan estimasi keadaan bola yang optimal. Keluaran *Kalman Filter* adalah posisi dan kecepatan bola yang telah dihaluskan dan diprediksi, siap diteruskan ke modul kontrol gerak robot.

Model yang dipilih adalah arsitektur YOLOv8, diimplementasikan menggunakan *framework* Ultralytics. Pemilihan YOLOv8 didasarkan pada keunggulannya dalam memberikan keseimbangan optimal antara kecepatan inferensi dan akurasi, yang sangat penting untuk mencapai kinerja *real-time* pada robot dengan sumber daya komputasi terbatas. Model ini bertanggung jawab untuk menghasilkan prediksi lokasi bola yang kemudian menjadi input bagi algoritma pelacakan *Kalman Filter*.

Setelah model YOLOv8 berhasil mendeteksi bola, data hasil deteksi diekstraksi. Data ini berbentuk bounding box dengan format (x_c, y_c, w, h, C) , di mana (x_c, y_c) adalah koordinat pusat bola pada citra, dan C adalah *confidence score*. Koordinat pusat (x_c, y_c) inilah yang dijadikan Vektor Pengukuran (Z_k) yang bising (*noisy*) dan siap diolah lebih lanjut oleh *Kalman Filter*. *Confidence score*

juga dapat dimanfaatkan untuk memverifikasi keandalan pengukuran saat proses pembaruan (koreksi) pada *Kalman Filter*.

Kalman Filter dikonfigurasi untuk memodelkan keadaan bola dengan 8 status (*state*) dan menerima 4 pengukuran (*measurement*).


- Vektor Keadaan (X): Mewakili posisi, dimensi, dan kecepatan perubahan objek, didefinisikan sebagai $[x, y, w, h, \dot{x}, \dot{y}, \dot{w}, \dot{h}]^T$. Di sini, x, y adalah koordinat pusat, w, h adalah lebar dan tinggi *bounding box*, dan $\dot{x}, \dot{y}, \dot{w}, \dot{h}$ adalah laju perubahan (kecepatan) dari variabel-variabel tersebut.
- Vektor Pengukuran (Z): Mewakili data yang diterima dari detektor YOLOv8 pada *frame* tertentu, didefinisikan sebagai: $[x, y, w, h]^T$.

Strategi *Frame Skipping* diterapkan untuk optimasi komputasi dan stabilisasi gerakan. Alur kerjanya adalah sebagai berikut:

1. Pengukuran YOLO (misal *frame* 1): Pada *frame* awal, YOLOv8 dijalankan untuk mendapatkan data pengukuran Z . Data ini digunakan untuk menginisialisasi atau memperbarui status *Kalman Filter*.
2. Prediksi *Kalman Filter* (*Skip Frames*): Untuk beberapa *frame* berikutnya (misalnya *frame* 2 hingga *frame* 5), sistem tidak menjalankan YOLO. Sebaliknya, *Kalman Filter* berada dalam mode prediksi penuh, menghasilkan posisi bola yang diestimasi berdasarkan model gerakan internalnya. Hal ini mengurangi beban komputasi secara signifikan.
3. Pengukuran Ulang YOLO (*frame* 6): Pada *frame* setelah pengukuran terakhir, YOLOv8 diaktifkan kembali untuk memberikan data pengukuran baru (Z_k) yang akan digunakan *Kalman Filter* untuk pembaruan (*update*). Siklus ini kemudian berulang.

Strategi ini juga meningkatkan ketahanan sistem terhadap *occlusion* sesaat. Jika YOLO gagal mendeteksi bola pada *frame* yang seharusnya (misalnya *frame* 1 atau *frame* 6), *Kalman Filter* akan diinstruksikan untuk tetap menjalankan langkah prediksi tanpa *update* dari YOLO. Untuk menjaga integritas pelacakan, batas toleransi kegagalan deteksi diatur maksimal 5 kali kejadian berturut-turut. Jika *Kalman Filter* harus terus memprediksi lebih dari 5 *frame* tanpa input YOLO

(misalnya karena bola hilang atau terhalang total), *track* (jejak) dianggap hilang (*Lost Track*), dan sistem akan kembali ke mode pencarian penuh.



Gambar 3.2 Strategi Implementasi Sistem Deteksi Dan Pelacakan

Implementasi *Kalman Filter* dilakukan menggunakan modul bawaan OpenCV, yang menyediakan fungsi-fungsi terstruktur untuk inisialisasi, prediksi, dan pembaruan, memanfaatkan operasi matriks yang dioptimalkan untuk performa *real-time*. Output status (x, y) yang dihaluskan dan diprediksi dari *Kalman Filter* kemudian digunakan oleh modul kontrol robot untuk menghasilkan perintah gerakan yang stabil dan responsif.

3.7. Desain dan Implementasi Kontrol Gerak Robot Berbasis Visi

Perancangan sistem menggunakan pendekatan pembagian fungsi antara dua platform, yaitu:

1. Unit Pemrosesan Visi (ROS): Laptop pada robot menjalankan ROS yang berfungsi membaca citra dari kamera, melakukan deteksi objek menggunakan

YOLO dan *Kalman Filter*, menentukan lokasi objek pada *grid*, dan menghasilkan perintah gerak diskrit.

2. Unit Eksekusi Gerak (Arduino Mega): Berfungsi menerima perintah gerak dari ROS melalui komunikasi serial, menerjemahkannya menjadi aksi motor, dan menjalankan manuver sesuai perintah.

Alur data utama pada sistem meliputi: kamera → deteksi YOLO → prediksi posisi *Kalman Filter* → identifikasi *grid* → perintah gerak → pengiriman melalui topik “master/command” → eksekusi pada Arduino. Pendekatan distribusi seperti ini memastikan proses pengolahan citra yang berat dilakukan di ROS, sedangkan Arduino hanya menjalankan fungsi aktuasi motor.

Informasi posisi objek dikonversi menjadi instruksi gerak melalui pembagian area pengamatan menjadi *grid*. Pembagian *grid* ditentukan berdasarkan hasil kalibrasi kamera sehingga setiap kotak merepresentasikan area tertentu pada bidang pandang.

Objek yang terdeteksi (misalnya bola) akan memiliki koordinat *grid* tertentu, misalnya (X_{grid}, Y_{grid}) . Koordinat tersebut dikategorikan ke dalam beberapa zona tindakan, seperti zona kiri, zona kanan, zona tengah, atau zona jauh. Setiap zona dipetakan ke instruksi gerak tertentu, antara lain:

- Zona tengah atas → robot bergerak maju.
- Zona kiri → robot melakukan koreksi arah ke kiri.
- Zona kanan → robot melakukan koreksi ke kanan.
- Zona bawah → robot melakukan putaran pencarian.
- Objek tidak terdeteksi → robot berhenti.

Pendekatan berbasis *grid* ini membuat sistem mudah diimplementasikan karena instruksi gerak ditentukan oleh lokasi visual secara langsung.

Komunikasi antara ROS dan Arduino dilakukan melalui Serial dengan format pesan berbasis *string*, misalnya “maju”, “putarKanan”, atau “majuPelan”. Node ROS menerbitkan perintah ini ke topik “master/command”, kemudian dikirimkan ke Arduino. Arduino berfungsi membaca pesan yang diterima, melakukan *parsing*, dan memanggil fungsi gerak yang sesuai. Setiap perintah memiliki fungsi motor tersendiri, misalnya fungsi untuk bergerak maju, berbelok, atau bergerak dengan

kecepatan rendah. Implementasi ini memungkinkan robot bergerak secara responsif berdasarkan keluaran pengolahan citra pada ROS.

3.8. Pengujian dan Evaluasi Kinerja

Tahap pengujian dilakukan untuk memvalidasi efektivitas integrasi algoritma *Kalman Filter* pada sistem deteksi YOLOv8 dalam mengatasi keterbatasan perangkat keras dan kondisi dinamis lapangan. Pengujian dirancang menggunakan pendekatan komparatif, yaitu membandingkan kinerja sistem dalam dua kondisi percobaan. Pertama, sistem hanya menggunakan deteksi YOLOv8 pada setiap frame tanpa prediksi (*frame-by-frame detection*) yang akan disebut kondisi *baseline*. Kedua, sistem menggunakan strategi *Frame Skipping* dengan YOLOv8 dan prediksi *Kalman Filter* (YOLO-KF) yang akan disebut kondisi *optimized*.

Evaluasi dilakukan pada tiga aspek utama: kinerja komputasi perangkat keras, akurasi pelacakan objek (termasuk penanganan *occlusion*), dan kualitas respons perintah gerak robot.

3.8.1. Skenario Pengujian

Pengujian dilakukan dengan serangkaian skenario terkontrol sebagai berikut:

1. Pengujian Kinerja Komputasi (*Computational Performance Test*)

Skenario ini bertujuan untuk membuktikan efisiensi sistem *Optimized* pada laptop ASUS K401U.

- **Prosedur:** Robot ditempatkan dalam posisi diam menghadap bola yang statis. Sistem dijalankan selama 60 detik untuk masing-masing kondisi (*baseline* dan *optimized*).
- **Pengambilan Data:** Sistem akan mencatat waktu proses (*inference time*) dan jumlah frame yang berhasil diproses per detik (*Frames Per Second / FPS*) secara *real-time* ke dalam *log file*.

2. Pengujian Akurasi Pelacakan dan Occlusion (*Tracking Accuracy & Occlusion Test*)

Skenario ini bertujuan menguji kemampuan algoritma mempertahankan posisi bola saat terjadi gangguan visual.

- **Prosedur Uji Lintasan Lurus:** Bola digelindingkan pada lintasan lurus yang telah ditandai di lantai (sebagai *Ground Truth*) sepanjang 2 meter. Posisi koordinat (x, y) yang dihasilkan sistem direkam dan dibandingkan dengan garis lintasan sebenarnya.
- **Prosedur Uji *Occlusion*:** Sebuah penghalang (kardus) ditempatkan di tengah lintasan sehingga bola tertutup total dari pandangan kamera robot selama beberapa saat.
- **Observasi:** Pada kondisi *optimized*, sistem diharapkan tetap menghasilkan koordinat prediksi posisi bola (jalur imajiner) di belakang penghalang, sedangkan pada kondisi *baseline*, data posisi akan hilang.

3. Pengujian Respons Gerak Robot (*Robot Response Test*)

Skenario ini bertujuan melihat kestabilan perintah gerak yang dikirimkan oleh unit pemrosesan visi (ROS) ke unit eksekusi gerak (Arduino).

- **Prosedur Uji *Jitter* (Guncangan):** Bola digerakkan ke kiri dan ke kanan dengan cepat (dikocok) di depan robot dalam area pandang yang sempit.
- **Prosedur Uji *Intersepsi*:** Bola digelindingkan menyilang di depan robot, dan robot harus mengirimkan perintah untuk merespons pergerakan tersebut.
- **Pengambilan Data:** *Data logger* akan merekam perubahan perintah (*command switching*) yang dikirim ke topik serial master/command (seperti "maju", "putarKanan", "putarKiri", "berhenti"). Fokus pengamatan adalah frekuensi perubahan perintah yang tidak perlu (*flickering command*) akibat *noise* deteksi.

3.8.2. Metrik Evaluasi Kinerja

Evaluasi kinerja difokuskan pada dua kelompok metrik, yaitu:

1. Metrik Kinerja Komputasi

- **Rata-rata FPS (*Average Frames Per Second*):** Nilai FPS yang lebih tinggi menunjukkan sistem lebih responsif dan ringan dijalankan pada perangkat keras yang tersedia.

- Stabilitas *Frame Rate*: Mengukur seberapa sering terjadi penurunan FPS (*frame drop*) drastis yang dapat menyebabkan *lag* pada robot.

2. Metrik Akurasi Pelacakan

- **Root Mean Square Error (RMSE)**: Mengukur selisih rata-rata antara posisi bola hasil deteksi/prediksi sistem dengan posisi sebenarnya (*Ground Truth*) pada lintasan lurus. Nilai RMSE yang lebih kecil menunjukkan akurasi yang lebih baik.
- **Success Rate on Occlusion**: Persentase keberhasilan sistem dalam memberikan *output* koordinat bola secara terus-menerus saat bola melewati area tertutup (*occlusion*).

3. Metrik Kualitas Respons (Log Perintah)

- **Frekuensi Command Switching**: Menghitung jumlah pergantian perintah gerak dalam satuan waktu tertentu saat merespons target yang sama. Contohnya, jika dalam 1 detik perintah berubah-ubah dengan cepat ("kiri" → "kanan" → "kiri"), ini mengindikasikan ketidakstabilan (*jitter*). Sistem *optimized* diharapkan menghasilkan aliran perintah yang lebih konsisten (misalnya: "kiri" → "kiri" → "kiri" → "maju") berkat penghalusan data oleh *Kalman Filter*.
- **Latensi Re-akuisisi**: Waktu yang dibutuhkan sistem untuk mengirimkan perintah gerak yang tepat kembali setelah bola keluar dari kondisi *occlusion*.

Dengan membandingkan hasil pengujian *baseline* (YOLO murni) dengan hasil *optimized* (YOLO + *Kalman Filter*), penelitian ini akan secara kuantitatif membuktikan sejauh mana *Kalman Filter* mampu mengoptimalkan gerakan robot Sepak Bola Beroda.

DAFTAR PUSTAKA

- Admaja, Y. P. (2021). *Sistem Penghitung Jumlah Pengunjung di Restoran Menggunakan Kamera Berbasis*. 3(1), 19–26.
- Baskoro, G. Y., Afrisal, H., & Sofwan, A. (2022). Perancangan Sistem Deteksi Objek Berbasis Convolutional Neural Network Menggunakan Yolov4 Dan Opencv. *Transient: Jurnal Ilmiah Teknik Elektro*, 11(4), 128–020637. <https://ejournal3.undip.ac.id/index.php/transient>
- Egi, Y. (2022). *Basketball self training shooting posture recognition and trajectory estimation using computer vision and Kalman filter*. 73, 19–27.
- Farhan, T. M., & Candra, F. (2025). CNN-Based Ball and Goal Detection for KRSBI Robot with Omnidirectional Camera. *International Journal of Electrical, Energy and Power System Engineering*, 8(2), 86–98. <https://doi.org/10.31258/ijeepse.8.2.1-13>
- Firdaus, A. Z., & Lelono, D. (2025). *Sistem Klasifikasi Sampah Otomatis Berbasis Deteksi Objek Real-Time Pada Single Board Computer Dengan Algoritma YOLO*. 15(1), 49–60. <https://doi.org/10.22146/ijeis.104520>
- Hendrik, B., & Awal, H. (2023). Pengenalan Teknologi Robot Pada Anak Sekolah Dasar. *Jurmas Bangsa*, 1(1), 46–52. <https://doi.org/10.62357/jpb.v1i1.140>
- Hodson, T. O. (2022). *Root-Mean-Square Error (RMSE) Or Mean Absolute Error (MAE): When To Use Them Or Not*. 2, 5481–5487.
- Jung, H., Kang, S., Kim, T., Kim, H., Klemove, H. L., & Korea, R. (2024). ConfTrack: Kalman Filter-based Multi-Person Tracking by Utilizing Confidence Score of Detection Box. *CVF Open Access*, 6583–6592.
- Kusumoputro, B., Purnomo, M. H., Rochardjo, H. S. B., Prabowo, G., Purwanto, D., Mozef, E., Indrawanto, Mutijarsa, K., & Muis, A. (2024). *Pedoman Kontes Robot Indonesia (Kri) Pendidikan Tinggi Tahun 2024*.
- Louda, S., Karkar, N., & Seghir, F. (2023). *Autonomous Navigation of a Differential Mobile Robot using Depth Camera Sensor-based ROS*.
- Miharja, G. P., Nugraha, D. A., & Aziz, A. (2025). Analisis Perbandingan Kinerja YOLO dan Camshift Dalam Pelacakan Objek Berbasis Video. *Jurnal Riset*

- Mahasiswa Bidang Teknologi Informasi Volume, 5*(Analisis Perbandingan Kinerja Yolo dan Camshift), 100–110.
- Mohammed, H. R., & Hussain, Z. M. (2021). *Detection and Recognition of Moving Video Objects: Kalman Filtering with Deep Learning. 12*, 154–157.
- Nanda, B. M., Siregar, S., & Sani, M. I. (2023). *Implementasi Object Detection Pada Robot Sepak Bola Beroda Berbasis Kamera Omnidirectional Menggunakan OpenCV. 9*(4), 2064–2068.
- NumPy. (2025). *NumPy*. <https://numpy.org/>
- Nuralim, J., Fath, N., Musafa, A., Sujono, & Broto, D. S. (2022). Perancangan Sistem Pendeteksian Obyek Bola Dengan Metode Framework YOLOv4. *Jurnal Maestro*, 5(2), 289–294. <https://jom.ft.budiluhur.ac.id/index.php/maestro/article/view/531>
- Quigley, M., Gerkey, B., Conley, K., Faust, J., Foote, T., Leibs, J., Berger, E., Wheeler, R., & Ng, A. (2009). *ROS: An Open-source Robot Operating System. Figure 1*.
- Ratna, S. (2020). Pengolahan Citra Digital Dan Histogram Dengan Phyton Dan Text Editor Phycharm. *Technologia: Jurnal Ilmiah*, 11(3), 181. <https://doi.org/10.31602/tji.v11i3.3294>
- Redmon, J., Divvala, S., Girshick, R., & Farhadi, A. (2016). You Only Look Once: Unified, Real-time Object Detection. *Proceedings of the IEEE Computer Society Conference on Computer Vision and Pattern Recognition, 2016-Decem*, 779–788. <https://doi.org/10.1109/CVPR.2016.91>
- Ritonga, A. A., & Hasibuan, E. R. (2025). *Eksplorasi Masa Depan Robotika : Integrasi Kecerdasan Buatan dalam Sistem Automasi Adaptif Berbasis Lingkungan. 1*, 387–393.
- Romario, M. H., & Kadarina, T. M. (2020). *Sistem Hitung Dan Klasifikasi Objek Dengan Metode Convolutional Neural Network. 11*(2), 108–114.
- Ryu, S. E., & Chung, K. Y. (2021). Detection Model Of Occluded Object Based On Yolo Using Hard-example Mining And Augmentation Policy Optimization. *Applied Sciences (Switzerland)*, 11(15). <https://doi.org/10.3390/app11157093>

- Saputra, C. (2023). Implementasi Algoritma SIFT (Scale-Invariant Feature Transform) Dan Algoritma Kalman Filter Dalam Mendeteksi Objek Bola. *Jurnal PROCESSOR*, 18(1), 73–82. <https://doi.org/10.33998/processor.2023.18.1.791>
- Saputra, F. B., Kallista, M., & Setianingsih, C. (2023). Deteksi social distancing dan penggunaan masker di restoran menggunakan algoritma Residual Network (ResNet). *EProceedings of Engineering*, 10(1), 284–295.
- Shofi, M., Basuki, B. M., & Habibi, A. (2023). Rancang Bangun Penendang Bola Pada Robot Soccer Unisma Menggunakan Solenoid. *Science Electro*, 16(4), 1–7.
- Sholehurrohman, R., Habibi, M. R., Ilman, I. S., Taufiq, R., & Muhaqiqin, M. (2023). Analisis Metode Kalman Filter, Particle Filter dan Correlation Filter Untuk Pelacakan Objek. *Komputika : Jurnal Sistem Komputer*, 12(2), 21–28. <https://doi.org/10.34010/komputika.v12i2.9567>
- Surya, M., Nehemia Toscani, A., Saputra, C., Pratama, Y., & Bustami, M. I. (2025). Penggunaan Yolo Untuk Deteksi Robot Dan Gawang Pada Robot Sepak Bola Beroda. *The Indonesian Journal of Computer Science*, 14(1), 1055–1070. <https://doi.org/10.33022/ijcs.v14i1.4575>
- Takura, K. E. I., Arita, Y. U. M. A. N., & Oaki, S. H. N. (2021). *Automatic pear and apple detection by videos using deep learning and a Kalman filter*. 4(5), 1688–1695.
- Taylor, L. E., Mirdanies, M., & Saputra, R. P. (2016). *Optimized Object Tracking Technique Using Kalman*. 07, 57–66. <https://doi.org/10.14203/j.mev.2016.v7.57-66>
- Ultralytics. (2025). *Kalman Filter (KF)*.
- Wakhidah, N., Pungkasanti, P. T., & Pinem, A. P. R. (2023). *Deteksi Objek menggunakan Deep Learning*. 9(3), 465–470.
- Widodo, Y. B., Sibuea, S., & Narji, M. (2024). Kecerdasan Buatan dalam Pendidikan: Meningkatkan Pembelajaran Personalisasi. *Jurnal Teknologi Informatika Dan Komputer*, 10(2), 602–615. <https://doi.org/10.37012/jtik.v10i2.2324>

- Wijaya, G. F., & Yuniarto, D. (2024). Tinjauan Penerapan Machine Learning pada Sistem Rekomendasi Menggunakan Model Klasifikasi. *Populer: Jurnal Penelitian Mahasiswa*, 3(4), 144–153. <https://doi.org/10.58192/populer.v3i4.2798>
- Yaseen, M. (2024). *What Is Yolov8: An In-Depth Exploration Of The Internal Features Of The Next-Generation Object Detector*. 8, 1–10.
- Yuztiawan, F. R., & Utaminingrum, F. (2017). Implementasi Metode Kalman Filter Dan Model Yolov8N Untuk Fitur Human-Following Pada Kursi Roda Pintar. *Jurnal Pengembangan Teknologi Informasi Dan Ilmu Komputer*, 1(1), 2548–2964.